

Diario di bordo

Progetto d'esame — riproduzione di *Audio Sparse-Transformer* (Kavaki & Mandel, ICASSP 2025)

B031278 Deep Learning, Fall 2025 — MSc in Artificial Intelligence, Università di Firenze

Ultimo aggiornamento: 17 agosto 2026

A COSA SERVE QUESTO DOCUMENTO

Registro cronologico di **tutto** ciò che viene fatto sul progetto: decisioni e loro motivazione, verifiche eseguite, **errori commessi** e cambi di direzione. Serve per ripassare, per ricostruire *perché* una scelta è stata fatta mesi dopo, e per rispondere all'orale a domande del tipo «perché hai fatto così e non cosà».

Il piano di lavoro sta invece in `Pipeline_progetto_DL.pdf` : quello dice *cosa* fare, questo dice *cosa è stato fatto*.

LEGENDA

DECISIONE scelta presa, con motivazione · **VERIFICA** qualcosa controllato o misurato · **ERRORE** sbaglio commesso · **CORREZIONE** rettifica di qualcosa detto o fatto prima · **ARTEFATTO** file prodotto

COME SI AGGIORNA

Il sorgente è `docs/diario_di_bordo.html` . Dopo averlo modificato:

```
powershell -File scripts\build_docs.ps1
```

rigenera `Diario_di_bordo.pdf` e `Pipeline_progetto_DL.pdf` nella cartella di progetto, usando Edge in modalità headless (nessuna dipendenza da installare).

Giorno 1 — mercoledì 12 agosto 2026

Obiettivo della sessione: capire cosa chiede l'esame, cosa dicono i due paper, e definire un metodo di lavoro.

VERIFICA Analisi della pagina del corso

Letta integralmente la pagina ufficiale (ai.dinfo.unifi.it/teaching/dl_2025.html), salvata in locale. Estratti i vincoli d'esame che condizionano ogni scelta tecnica:

- progetto da **concordare a ricevimento** (lunedì 10:45–12:45, S. Marta): il docente dà i dettagli operativi;
- **nessuna relazione scritta** — si consegna solo codice più istruzioni di riproduzione, quindi il `README.md` è l'unico documento valutato;
- consegna su **repository privato Codeberg** con l'utente `dl.unifi` invitato; **mai i dati**, solo un link;
- presentazione di **30 minuti** con letteratura, derivazione tecnica ed esperimenti; domande individuali su tutto il programma;
- riduzione di dataset e modelli **esplicitamente autorizzata** se le risorse non bastano;
- esiste un **form Google per richiedere risorse di calcolo**.

Annotato l'avvertimento del docente sul leggere «other ancestors in the citation graph»: si rivelerà centrale il giorno 2.

VERIFICA Ricerca sui due paper assegnati

Gazneli et al. 2022 (EAT): arXiv ad accesso libero, codice ufficiale su github.com/Alibaba-MIIL/AudioClassification. Estratti architettura (conv 1D depthwise su waveform grezza + transformer), varianti EAT-S 5,3 M / EAT-M 25,5 M, le augmentation proposte (Mixup, FreqMix, PhaseMix, TimeMix/CutMix) e la ricetta di training (AdamW, one-cycle, EMA 0,995, label smoothing, BCE).

Kavaki & Mandel 2025: risultato **closed access**, nessun preprint arXiv, nessun codice pubblico. Semantic Scholar riporta `openAccessPdf: CLOSED` e reference list elisa dall'editore. Disponibile solo l'abstract: 96,88 % su Speech Commands V2 con -85,25 % di FLOPs rispetto a EAT-S.

ERRORE Ipotesi sbagliata sull'origine del metodo

Non potendo leggere il paper, è stata formulata l'ipotesi che le «regioni significative» dello spettrogramma derivassero dalla linea di ricerca precedente di Mandel sulle *importance map* — *Identifying Important Time-Frequency Locations* (Interspeech 2020) e *ImportantAug* (ICASSP 2022) — e che il decoding fosse un embedding di punti con encoding posizionale continuo, cioè lo spettrogramma trattato come point cloud.

L'ipotesi era sbagliata ed è stata smentita il giorno 2 leggendo il PDF. Il vero ancestor è SparseFormer. Vedi la voce del 17/08. L'ipotesi era stata comunque marcata come «da confermare, non da dare per buona»: la lezione è che un'ipotesi plausibile su un metodo non letto resta una congettura, e va tenuta separata dai fatti.

DECISIONE Struttura del lavoro in sei fasi

Definito un piano che mette **l'infrastruttura di misura prima del modello**. Motivazione: il claim da riprodurre è un *rapporto* accuratezza/FLOPs, non un'accuratezza; un contatore di FLOPs scritto dopo il modello tende a essere costruito per confermare il risultato atteso.

Definiti anche i **criteri di successo in anticipo**, per non poterli riscrivere a posteriori in base a quello che esce.

VERIFICA Ricognizione della macchina

GPU	NVIDIA GeForce RTX 5050 Laptop, 8151 MiB, driver 592.82 — Blackwell, sm_120
Python di sistema	3.12.4
Disponibili	miniconda, git — uv assente, PyTorch non installato

Verificati i due ambienti DL esistenti: `C:\ai\pytorch_env` (torch 2.9.1+cu128, Python 3.12.4) e conda `DLA2026` (torch 2.10.0, CUDA 13, Python 3.14.3). **Entrambi già compatibili con sm_120**. In entrambi mancavano però `soundfile` e `numba`, e `torchaudio` era nella variante `+cpu`.

DECISIONE Ambiente dedicato invece di riusare quelli esistenti

Scelto di creare un venv nuovo su Python 3.12 anziché usare `pytorch_env` o `DLA2026`. Tre motivi:

- **riproducibilità**: un `pip freeze` da un ambiente generalista con JAX, OpenCV, mediapipe e pyautogui produce un `requirements.txt` inutilizzabile, e l'ambiente è parte del deliverable;
- `DLA2026` appartiene a **un altro corso**: modificarlo rischia di romperne il lavoro;
- Python 3.14 di `DLA2026` taglierebbe fuori `numba`/librosa se dovessero servire.

ERRORE Generazione del PDF fallita al primo tentativo

Il primo tentativo di conversione HTML→PDF con Edge headless non ha prodotto alcun file. Causa: un flag inesistente (`--print-to-pdf-no-header`) e il profilo utente di Edge bloccato da un'istanza attiva. **Risolto** passando un `--user-data-dir` dedicato e terminando i processi `msedge` residui. La ricetta funzionante è ora in `scripts/build_docs.ps1`.

ARTEFATTO Prodotti i primi due file

- `Pipeline_progetto_DL.pdf` **v1.0** — 14 pagine: vincoli d'esame, analisi dei paper, pipeline in 6 fasi, protocollo sperimentale, piano di studio a 10 settimane, programma del corso come checklist, derivazioni da saper fare, struttura del repo;
- `requirements.txt` — installazione in due passi, con la motivazione di ogni pacchetto non ovvio.

Giorno 2 — lunedì 17 agosto 2026

Obiettivo: leggere il paper vero, correggere il piano, costruire l'infrastruttura della Fase 2.

VERIFICA

I PDF dei paper sono arrivati

Trovati nella cartella: 2204.11479v5.pdf (EAT), Audio_Sparse-Transformer_for_Speech_Classification.pdf (copia UNIFI da IEEE Xplore) e una cartella paper pre progetto/ con ViT, Attention is all you need e arXiv 2304.03768.

CORREZIONE

Ostacolo tecnico: lettura dei PDF

Lo strumento di lettura PDF richiedeva poppler, non installato e non installabile sul momento. Aggirato usando PyMuPDF, già presente nell'ambiente conda DLA2026, per estrarre il testo in un file temporaneo. Utile ricordarlo: gli ambienti esistenti sono una risorsa anche quando non li si usa per il progetto.

CORREZIONE

L'ancestor era un altro — ipotesi del giorno 1 smentita

Letto il paper per intero. Il metodo non deriva dalla linea importance-map di Mandel. L'origine è SparseFormer (Gao et al. 2023, arXiv:2304.03768, Sparse visual recognition via limited latent tokens), un modello per ImageNet di cui questo lavoro è la trasposizione all'audio. Gli altri due riferimenti strutturali sono Faster R-CNN (parametrizzazione delle regioni) e AdaMixer (pesi di decoding adattivi).

Differenza sostanziale rispetto all'ipotesi: le regioni non sono selezionate per saliency o energia — sono parametri appresi, aggiustati iterativamente dai token stessi. E il transformer non usa positional encoding, perché i token non hanno ordine.

Nota: 2304.03768 era già nella cartella paper pre progetto/. L'ancestor giusto era a disposizione fin dall'inizio.

DECISIONE

Cambio di direzione: il baseline non è EAT-S

Dalla Tabella 2 del paper emerge che il confronto controllato non è contro EAT-S ma contro il dense-transformer degli autori: stessa architettura che processa i frame temporali invece dei token latenti. Il numero di EAT-S è citato dalla letteratura, non rimisurato dagli autori.

Modello	Params	FLOPs	Accuracy
Sparse-transformer (N=4, P=36)	2,87 M	0,055 G	96,88 %
Dense-transformer	4,80 M	0,645 G	96,67 %
EAT-S (citato)	5,30 M	0,373 G	98,15 %

Conseguenza sul piano: la Fase 3 diventa «early convolution + dense transformer», che condivide tutto il codice a valle col modello sparso; la reimplementazione completa di EAT-S scende a Fase 4-bis, opzionale. Semplificazione netta e riduzione del rischio.

VERIFICA

Il metodo, ricavato dal paper

N token latenti e N regioni $b=(x,y,w,h)$, entrambi parametri appresi; centri inizializzati su griglia, larghezze a metà della dimensione della feature map. Per $L_{rep}=3$ volte: aggiustamento della regione via $Linear(t)$ con parametrizzazione esponenziale → campionamento di P punti con offset appresi e interpolazione bilineare → decoding adattivo con M_c e M_s generati da t, GELU, update residuo del token. Poi 8 transformer-encoder, average pooling, classificatore lineare.

Configurazione: $N=4$, $P=36$, $d_{\text{token}}=64$, $d_{\text{encoder}}=128$, $L_{\text{enc}}=8$. Training: AdamW lr $3 \cdot 10^{-4}$, $\beta=(0,9 \cdot 0,99)$, one-cycle, wd 10^{-5} , EMA 0,995, batch 64, augmentation *mixing* e *phasemix*.

Dettaglio critico: non si campiona dallo spettrogramma diretto — il gradiente attraverso l'interpolazione bilineare è troppo rumoroso con pochi punti. Si applica prima una *early convolution* e si campiona sul suo output.

VERIFICA Ambiguità trovate nel paper

Sei punti su cui il paper tace o si contraddice, tutti da dichiarare come assunzioni:

- **parametri dello spettrogramma mai dichiarati** (mel o lineare? n_{fft} ? hop? bin?) — il parametro libero più impattante;
- **contraddizione interna in §3.2:** feature «96 dimensional» ma «196 kernels» 7×7 stride 2;
- numero di layer della early convolution non dichiarato;
- numero di epoche non dichiarato;
- come il dense-transformer costruisce i frame dall'output della early conv;
- convenzione FLOPs vs MAC non dichiarata.

Osservazione critica aggiuntiva: nella Tabella 3 l'ablation sui token **non è monotona** (16 token $\rightarrow$ 97,53 %, 25 token $\rightarrow$ 97,20 %, 36 $\rightarrow$ 97,94 %) e i risultati sono su **singolo seed**. Suggerisce un rumore da seed di 0,3–0,4 punti, paragonabile a diverse delle differenze discusse nel paper. È la giustificazione sperimentale dei ≥ 3 seed.

CORREZIONE Stima sbagliata della dimensione della cache

Nella v1.0 del PDF la cache del training set era stimata « $\approx 1,7$ GB». Valore corretto: **2,72 GB** ($84\,843 \times 16\,000$ campioni $\times$ 2 byte). Con validation e test si arriva a $\sim 3,4$ GB. Corretto nel PDF e nel codice.

ARTEFATTO Pipeline_progetto_DL.pdf v2.0 — 16 pagine

§3 riscritta col metodo reale e le formule; §3.4 nuova con le ambiguità; Fase 3 riscritta e Fase 4-bis aggiunta; §5.1 con gli split esatti e i target di riproduzione; §8 con tre derivazioni in più; §12 con la bibliografia corretta.

ARTEFATTO Codice della Fase 2

src/data/speech_commands.py	download, split ufficiali, cache mmap
src/data/dataset.py	Dataset e DataLoader
src/data/features.py	log-mel su GPU
src/data/augment.py	mixing e phasemix su GPU
src/flops.py	doppio contatore + latenza
src/utils.py	seed, config, EMA
scripts/check_env.py	verifica ambiente
scripts/prepare_data.py	Fase 2 completa
configs/base.yaml	assunzioni marcate [ASSUNZIONE]
README.md	.gitignore

Scelta di progettazione: `build_splits()` **fallisce di proposito** se i conteggi non danno esattamente $84\,843 / 9\,981 / 11\,005$. Sono i numeri dichiarati dal paper e coincidono con gli elenchi ufficiali speaker-disjoint: è un test di correttezza gratuito.

ERRORE Cancellazione accidentale di src/ e scripts/

Alle **16:54**, contestualmente alla creazione del venv `DL_F`, le cartelle `src/` e `scripts/` sono state eliminate insieme a un primo `.venv` — presumibilmente una multi-selezione sfuggita durante la pulizia del primo tentativo di ambiente. Metà del codice del progetto è sparita senza che ci fosse ancora un repository git.

Recuperate dal cestino e riverificate: tutti i file alle dimensioni originali, tutti ricompilano.

Lezione: il repository git va inizializzato *subito*, non «quando il codice sarà pronto». Un `git init` più un commit avrebbero reso l'incidente un non-evento.

CORREZIONE `.gitignore` non copriva il `venv`

Il `.gitignore` ignorava `.venv/`, ma l'ambiente si chiama `DL_F`: al primo `git add` sarebbero finiti sotto controllo di versione diverse migliaia di file. Aggiunta la riga `DL_F/`.

VERIFICA Installazione dell'ambiente

Verificata la raggiungibilità di **entrambi** gli indici pacchetti — `pypi.org` e `download.pytorch.org/whl/cu128` — prima di iniziare: se il secondo non risponde, pip ripiega silenziosamente sulla build CPU-only. Aggiornati pip (`24.0` → `26.2.1`), `setuptools` e `wheel`.

Installazione di torch avviata in background e **interrotta su richiesta**, ma il pacchetto era già stato installato per intero e funzionante. L'installazione è stata poi completata manualmente.

Esito di `scripts/check_env.py`:

```
torch 2.9.1+cu128 · CUDA 12.8 · capability (12, 0) · kernel di prova OK
arch compile: sm_70 ... sm_100, sm_120
torchaudio 2.9.1+cu128 · soundfile 0.14.0 · numpy 2.5.2
yaml 6.0.3 · fvcore 0.1.5 · einops 0.8.2 · optuna 4.9.0
=> ambiente pronto
```

VERIFICA Suite di test: 18 su 18 passati

Scritta `tests/test_pipeline.py`, eseguibile **senza dataset**: forme del front-end, invarianti delle augmentation, contatore di FLOPs, EMA, riproducibilità dei seed. Eseguita prima del download di 2,3 GB, per separare i bug dell'infrastruttura da quelli del modello.

Risultati notevoli:

- front-end conferma la forma `[B, 1, 64, 101]` — quel **101** è la T del modello denso, che il modello sparso riduce a **$N=4$** token: il fattore ~ 25 da cui viene il guadagno;
- **rapporto FLOPs/MAC verificato empiricamente**: su un `Linear(100→200)` senza bias, fvcore riporta 20 000 e il contatore nativo di torch 40 000 — **esattamente 2,000000**. L'avvertenza di `src/flops.py` non è più un'ipotesi;
- EMA con decay 0,9 si sposta di esattamente $1 - \text{decay} = 0,1$: la media mobile insegue, non copia.

DECISIONE Sorgenti della documentazione dentro al progetto

I sorgenti HTML dei PDF stavano in una cartella temporanea legata alla singola sessione di lavoro, quindi non ritrovabili in futuro. Spostati in `docs/` e aggiunto `scripts/build_docs.ps1` per rigenerare entrambi i PDF con un comando. Ora i documenti sono manutenibili e versionabili come il resto del codice.

Registro delle decisioni

Data	Decisione	Motivazione
12/08	Infrastruttura di misura prima del modello	Il claim è un rapporto accuratezza/FLOPs: un contatore scritto dopo tende a confermare il risultato atteso.
12/08	Venv dedicato, non riuso di ambienti esistenti	Riproducibilità (l'ambiente è parte del deliverable); DLA2026 appartiene a un altro corso.
12/08	Criteri di successo definiti in anticipo	Per non poterli riscrivere a posteriori in base ai risultati.
12/08	Installazione pip in due passi	<code>--index-url</code> sostituisce PyPI; <code>--extra-index-url</code> esporrebbe a dependency confusion.
17/08	Baseline = dense-transformer, non EAT-S	È il confronto controllato del paper; EAT-S è un numero citato. Riduce il lavoro e il rischio.
17/08	Split ufficiali con verifica bloccante dei conteggi	Speaker-disjoint; i tre numeri dichiarati dal paper sono un test di correttezza gratuito.
17/08	Ogni assunzione marcata [ASSUNZIONE]	Il paper tace su sei punti: vanno dichiarati, non nascosti. È materiale da presentazione.
17/08	Test prima del download del dataset	Separare i bug dell'infrastruttura da quelli del modello costa 2 secondi invece di ore.
17/08	Sorgenti dei documenti in docs/	Erano in una cartella temporanea di sessione: non ritrovabili in futuro.

Errori e correzioni

Data	Cosa è andato storto	Esito
12/08	Ipotesi sbagliata sull'ancestor del metodo (importance-map di Mandel)	Smentita il 17/08: è SparseFormer. Era marcata «da confermare», ma resta una congettura presa per plausibile troppo a lungo.
12/08	Stima della cache: 1,7 GB	Valore corretto 2,72 GB . Corretto in PDF e codice.
12/08	Generazione PDF fallita (flag inesistente, profilo Edge bloccato)	Risolto con <code>--user-data-dir</code> dedicato; ricetta salvata in <code>scripts/build_docs.ps1</code> .
17/08	Lettura PDF impossibile (poppler mancante)	Aggirato con PyMuPDF dall'ambiente DLA2026.
17/08	Cancellazione di src/ e scripts/	Recuperate dal cestino, verificate. Lezione: inizializzare git subito.
17/08	.gitignore copriva .venv/ ma l'ambiente si chiama DL_F	Aggiunta la riga mancante prima del primo <code>git add</code> .

Stato al 17 agosto 2026

Fase	Contenuto	Stato
0	Lettura paper + ancestor, setup	paper letti; SparseFormer ancora da leggere ; form risorse e ricevimento da fare
1	Prerequisiti teorici	in corso, in parallelo
2	Dati, split, contatore FLOPs	codice scritto e testato (18/18) ; download dataset in corso
3	Early conv + dense transformer	da fare — prossimo passo
4	Sparse feature extractor	da fare
4-bis	EAT-S (<i>opzionale</i>)	da fare
5	Ablation, seed multipli, HPO	da fare
6	Presentazione	da fare

QUESTIONI APERTE

- **Leggere SparseFormer** (`paper pre progetto/2304.03768v1.pdf`): è dove il metodo è spiegato per esteso.
- **Inizializzare il repository git** — priorità alta dopo l'incidente del 17/08.
- Compilare il **form per le risorse di calcolo** e fissare il **ricevimento** col docente.
- Risolvere la contraddizione «96 dimensional» vs «196 kernels» implementando entrambe le letture.
- Calibrare la convenzione FLOPs/MAC del paper misurando EAT-S con entrambi i contatori.
- Verificare la formula di *PhaseMix* contro il codice ufficiale di EAT.

Diario di bordo del progetto d'esame B031278 — Deep Learning, Fall 2025, Università di Firenze. Documento di lavoro personale, aggiornato a ogni sessione. Sorgente: `docs/diario_di_bordo.html` — rigenerare con `scripts/build_docs.ps1`.