

Manuale tecnico

Riproduzione di *Audio Sparse-Transformer for Speech Classification*

Kavaki & Mandel, ICASSP 2025

Progetto d'esame — B031278 Deep Learning, Fall 2025

MSc in Artificial Intelligence, Università di Firenze

Versione 1.2 — 18 agosto 2026 · documento vivo, aggiornato a ogni sessione

v1.1: consultato il codice di *SparseFormer* e di *EAT*. Corrette le formule di *mixing* e *phasemix*, la sequenza dello stem e il default della normalizzazione; risolte la formula degli offset e l'inizializzazione a griglia.

v1.2: letti *trainer.py* e *helper_funcs.py* di *EAT*. Chiusi i parametri di *one-cycle*, la programmazione delle augmentation e il criterio del weight decay; corretto il target mixato in multi-hot con soglia; chiarita la giustificazione del mel.

COME LEGGERE QUESTO MANUALE

Documenta **tutto**: la matematica sottostante, l'architettura, ogni scelta implementativa e la sua motivazione. È pensato per due usi: ripassare in vista dell'orale, e poter rispondere a «perché hai fatto così» su qualunque riga di codice.

Tre marcatori ricorrono nel testo:

DAL PAPER dichiarato esplicitamente da Kavaki & Mandel · **ASSUNZIONE** scelta nostra su un punto in cui il paper tace · **EVIDENZA** supportato da una misura che abbiamo eseguito.

Documenti fratelli: *Pipeline_progetto_DL.pdf* (il piano) e *Diario_di_bordo.pdf* (la cronaca, con gli errori).

INDICE

1. Il problema e l'inquadramento — keyword spotting, i due paper, la catena di ancestors
2. Dalla forma d'onda allo spettrogramma — STFT, scala mel, logaritmo, normalizzazione
3. Il transformer — attenzione, scaling, complessità, pre-norm, codifica posizionale
4. Convoluzione e early convolution — aritmetica, campo recettivo, perché serve
5. Ottimizzazione — da SGD ad AdamW, one-cycle, EMA
6. Loss e augmentation — softmax, BCE, mixup, phasemix
7. Il metodo sparso, per intero — regioni, campionamento, decoding adattivo
8. La ricostruzione del modello denso — vincoli numerici, ricerca, risultati
9. Catalogo delle assunzioni — ognuna con la sua evidenza
10. Il codice, file per file
11. Protocollo sperimentale e misura
12. Riferimenti

1 · Il problema e l'inquadramento

1.1 Che cosa stiamo classificando

Il compito è **keyword spotting**: data una registrazione di un secondo contenente una singola parola pronunciata, dire quale delle 35 parole del vocabolario è. Il dataset è *Google Speech Commands V2* (Warden 2018): 105 829 clip a 16 kHz.

È un problema di classificazione a 35 classi, con due caratteristiche che ne determinano il trattamento. Primo: gli esempi sono **corti e di lunghezza fissa**, quindi non serve gestire sequenze di lunghezza variabile né allineamento. Secondo: il compito è pensato per **dispositivi a risorse limitate** — un assistente vocale che ascolta in continuo — e per questo il costo computazionale è una metrica di prima classe, non un dettaglio.

1.2 I due paper e il loro rapporto

Gazneli et al. 2022 — EAT. Rete end-to-end che opera sulla *forma d'onda grezza*, senza spettrogramma: stack di convoluzioni 1D seguito da un encoder transformer. Il contributo dichiarato non è l'architettura ma un insieme di *augmentation audio*. EAT-S ha 5,3 M parametri e riporta 98,15 % su Speech Commands.

Kavaki & Mandel 2025 — Audio Sparse-Transformer. Osserva che la complessità della self-attention cresce quadraticamente con la lunghezza della sequenza, e che nell'audio le dipendenze a lungo raggio contano poco. Sostituisce quindi la lunga sequenza di frame temporali con una **sequenza cortissima di token latenti** — quattro — ottenuti campionando poche regioni informative dello spettrogramma. Riporta 96,88 % con 2,87 M parametri e 0,055 G FLOPs.

IL PUNTO CHE HA RISTRUTTURATO IL NOSTRO PIANO

Il confronto *controllato* del paper non è contro EAT-S, ma contro il proprio **dense-transformer**: la stessa identica architettura che processa la sequenza dei frame temporali invece dei token latenti (96,67 %, 4,80 M, 0,645 G). Il numero di EAT-S è **citato dalla letteratura**, non rimisurato dagli autori.

Conseguenza: il baseline da riprodurre per primo è il denso, non EAT-S. Condivide con lo sparso tutto il codice a valle e isola i bug del training loop da quelli del tokenizer.

1.3 La catena di ancestors

Il metodo non nasce nell'audio. È la trasposizione di **SparseFormer** (Gao et al. 2023), un modello per ImageNet che riconosce immagini campionando poche regioni invece di processare tutti i patch. Da SparseFormer arrivano tre componenti, ciascuna con la propria origine:

Componente	Origine
Parametrizzazione delle regioni	Faster R-CNN (Ren et al. 2015) — la codifica (Δx , Δy , $\log \Delta w$, $\log \Delta h$) delle bounding box
Decoding adattivo	AdaMixer (Gao et al. 2022) — pesi di mixing generati dalla query invece che fissi
Front-end convolutivo	Xiao et al. 2021 — <i>Early Convolutions Help Transformers See Better</i>

Leggere SparseFormer non è opzionale: le cinque pagine ICASSP comprimono in tre formule ciò che lì è esposto per esteso.

1.4 Il codice di riferimento: cosa abbiamo consultato, e per cosa

La consegna chiede di reimplementare il metodo *in modo autonomo*. La pagina del corso prevede però esplicitamente che «reading other ancestors in the citation graph may be necessary», specialmente «when dealing with the details of the experimental procedures». Questa sezione dichiara esattamente cosa è stato consultato e a quale scopo. **Nessuna riga è stata copiata.**

Paper	Repository	Uso
Kavaki & Mandel 2025	nessuna	Verificato leggendo tutte e cinque le pagine: nessun link, nessuna menzione di codice pubblico. Il metodo è reimplementato dalle sole formule del paper.
SparseFormer Gao et al. 2023	github.com/showlab/sparseformer file: imagenet/models/sparseformer.py	Sciolte tre ambiguità che il paper ICASSP lascia aperte: la formula della normalizzazione «a tre deviazioni standard» (§7.3), l'inizializzazione di token e regioni (§7.1), e la sequenza esatta dello stem convolutivo (§4.3).
EAT Gazneli et al. 2022	github.com/Alibaba-MIIL/ AudioClassification file: datasets/batch_augs.py , trainer.py , utils/helper_funcs.py	Ricavate le formule di <code>mixing</code> e <code>phasemix</code> (§6.3), la loro programmazione e la costruzione del target mixato (§6.3.4–5), i parametri di one-cycle (§5.3) e il criterio del weight decay (§5.2).

PERCHÉ QUESTA CONSULTAZIONE ERA NECESSARIA

Una prima versione delle augmentation, scritta dalle sole descrizioni testuali, è risultata **sbagliata su quasi tutti i dettagli**: trasformata sbagliata, ampiezza mescolata invece che preservata, distribuzione di λ sbagliata, peso dell'etichetta sbagliato. Nessuno di questi errori era rilevabile dal testo del paper.

Attenzione alla versione: il repository di SparseFormer contiene anche una libreria `sparseformer/` corrispondente alle versioni ICLR 2024 e CVPR 2024, *successive e diverse*. Il file rilevante è quello sotto `imagenet/` , che implementa la v1 (arXiv:2304.03768), cioè la versione che Kavaki & Mandel citano.

2 · Dalla forma d'onda allo spettrogramma

2.1 Perché non lavorare sul segnale grezzo

Una clip di un secondo a 16 kHz è un vettore di 16 000 campioni. Un transformer che trattasse ogni campione come token affronterebbe una sequenza di lunghezza 16 000, con una matrice di attenzione da $2,56 \cdot 10^8$ elementi per testa: impraticabile. Serve una rappresentazione che comprima il tempo preservando il contenuto fonetico. EAT risolve il problema con convoluzioni 1D a stride elevato; Kavaki & Mandel usano invece la rappresentazione tempo-frequenza classica.

2.2 Short-Time Fourier Transform

Si divide il segnale in finestre brevi e sovrapposte, su ciascuna si calcola la trasformata di Fourier discreta. Detto $x[n]$ il segnale e $w[n]$ una finestra di lunghezza L :

$$X[m, k] = \sum_{n=0}^{L-1} x[n + m \cdot H] \cdot w[n] \cdot e^{-j2\pi kn/L} \quad (2.1)$$

dove m indicizza il frame temporale, k il bin di frequenza e H è l'*hop*, cioè l'avanzamento fra finestre consecutive.

Il compromesso fondamentale è quello di Heisenberg per l'analisi tempo-frequenza: una finestra lunga dà buona risoluzione in frequenza ($\Delta f \approx f_s/L$) ma cattiva nel tempo; una corta il contrario. Per il parlato la convenzione è una finestra di **20–30 ms**, che è la scala su cui l'apparato fonatorio si può considerare stazionario, con hop di **10 ms**.

2.3 La scala mel

La percezione umana dell'altezza non è lineare in frequenza: distinguiamo bene 200 da 300 Hz, quasi nulla 8000 da 8100 Hz. La scala mel modella questa compressione:

$$m(f) = 2595 \cdot \log_{10}(1 + f / 700) \quad (2.2)$$

Si costruisce quindi un banco di M filtri triangolari equispaziati in *mel*, e si proietta lo spettro di potenza $|X[m, k]|^2$ su questa base. Il risultato è una matrice $M \times T$ molto più compatta dello spettrogramma lineare, con risoluzione fine alle basse frequenze — dove stanno formanti e armoniche della voce — e grossolana alle alte.

2.4 Il logaritmo

Si applica infine il logaritmo alle energie di banda. Tre ragioni, tutte solide:

- **percettiva**: la sonorità percepita è approssimativamente logaritmica nell'intensità (legge di Weber-Fechner);
- **statistica**: le energie hanno distribuzione fortemente asimmetrica con code lunghe; il logaritmo le rende quasi gaussiane, che è il regime in cui le reti si addestrano meglio;
- **algebrica**: un guadagno moltiplicativo sul segnale (registrare più forte) diventa un *offset additivo* costante sullo spettrogramma logaritmico. Questo trasforma un fastidio moltiplicativo in uno additivo, che una normalizzazione o una BatchNorm rimuove banalmente.

2.5 I nostri parametri, e perché EVIDENZA

Il paper **non dichiara alcun parametro dello spettrogramma**: né il tipo, né `n_fft`, né l'*hop*, né il numero di bin. Avevamo identificato questo come il grado di libertà potenzialmente più impattante dell'intera riproduzione. Lo abbiamo misurato.

Esperimento (sonda lineare). Per ciascun valore di M si calcolano le log-mel di 12 000 clip di training e 4 000 di validation, si mediano su 8 finestre temporali, si standardizzano e si addestra una *regressione logistica multinomiale* — un solo strato lineare. L'accuratezza risultante misura quanta informazione *linearmente decodificabile* contiene la rappresentazione, senza coinvolgere alcun modello profondo.

bin mel	dim. feature	accuratezza sonda	F dopo lo stem
32	256	41,60 %	8
40	320	41,93 %	10
64	512	42,18 %	16
80	640	42,40 %	20
128	1024	42,03 %	32

IL RISULTATO SMENTISCE LA PREOCCUPAZIONE INIZIALE

L'escursione fra il peggiore e il migliore è di **0,8 punti percentuali** su un intervallo di risoluzione che varia di un fattore quattro, e la curva **non è monotona**: 128 bin fanno peggio di 80. Il parametro che temevamo dominante è in realtà quasi **piatto**.

Scegliamo **64 bin**: sta a 0,22 punti dal migliore — differenza dentro il rumore — ed è l'unico valore che dopo lo stem convolutivo produce $F = 16$, una potenza di due. Questo conta perché il modello sparso inizializza le regioni «a metà della dimensione della feature map» e ne campiona l'interno: una griglia 16×51 è geometricamente più pulita di una 20×51 .

Limite dichiarato: la sonda lineare è un *lower bound*. Un modello profondo potrebbe sfruttare la risoluzione in modi che un classificatore lineare non vede. L'evidenza giustifica il non accanirsi, non dimostra l'ottimalità.

Parametri finali: $n_fft = 400$ (25 ms), $hop = 160$ (10 ms), $M = 64$, $f \in [20, 7600]$ Hz. Una clip da un secondo produce $16000/160 + 1 = 101$ frame.

MEL O SPETTROGRAMMA LINEARE? EVIDENZA

Domanda più fondamentale del numero di bin, e per un po' l'avevamo data per scontata. Il paper scrive sempre «*spectrogram*» per il proprio modello; l'unica volta che dice «*Mel-spectrogram*» è descrivendo KWT, un lavoro altrui. Tecnicamente, quindi, non lo dichiara.

Il sostegno alla scelta del mel viene da tre fonti, nessuna delle quali è EAT:

- **KWT** (Berg et al. 2021), il modello più vicino al nostro compito — keyword spotting su Speech Commands con un transformer — usa, per parola dello stesso Kavaki, «a sequence of non-overlapping **Mel-spectrogram** patches»;
- **AST** (Gong et al. 2021), l'altro riferimento citato, opera su spettrogrammi 2D con banco mel;
- EAT stesso, pur non usandolo, riporta che i sistemi di riconoscimento audio si basano «mostly on a **mel-spectrogram** representation» e cita una comparazione sistematica fra rappresentazioni che ne deduce la *superiorità*.

UNA PRECISAZIONE CHE VA FATTA

Sarebbe scorretto giustificare il mel dicendo «lo usa l'altro paper assegnato»: **EAT non usa affatto il mel**. Anzi, la sua tesi centrale è l'opposto — opera sulla forma d'onda grezza e argomenta esplicitamente che «the use of mel-spectrogram comes at the cost of having to carefully adjust the parameters for time-frequency resolution and compression».

La conclusione (usare il mel) resta valida, ma poggia su KWT, su AST e sulla comparazione che EAT cita — non su EAT. All'orale un'affermazione giusta con la motivazione sbagliata è peggio di un dubbio dichiarato.

2.6 Normalizzazione per-campione ASSUNZIONE EVIDENZA

Avevamo aggiunto una normalizzazione che porta ogni spettrogramma a media 0 e deviazione 1. La motivazione era che in Speech Commands il livello di registrazione varia enormemente. **Abbiamo misurato entrambe le cose**: quanto varia, e se la normalizzazione aiuta.

Quanto varia, su 20 000 clip di training:

```
percentili del livello RMS      p1  -40,6 dB    p25  -29,7 dB
                                p50  -24,4 dB    p75  -20,7 dB
                                p99  -12,0 dB

escursione p1-p99 : 28,5 dB ->  fattore 27x in ampiezza
```

La premessa è quindi vera e non di poco: la stessa parola può arrivare al modello con ampiezze che differiscono di oltre un ordine di grandezza.

MA L'EVIDENZA NON SOSTIENE LA NOSTRA AGGIUNTA

Ripetendo la sonda lineare a 64 bin con e senza normalizzazione:

```
con normalizzazione   : 42,33 %
senza normalizzazione : 42,83 %
```

La normalizzazione **peggiora** di mezzo punto. L'interpretazione plausibile è che il livello assoluto porti un po' di segnale utile — o correli con condizioni di registrazione che a loro volta correlano con le classi — e che azzerarlo distrugga questa informazione.

Decisione: default `normalize=False`. La variante resta un flag e diventa una delle ablation dichiarate, non un default silenzioso. A rafforzare la scelta: **né il paper né i due ancestor** — SparseFormer ed EAT, il cui codice abbiamo letto — normalizzano lo spettrogramma. Non abbiamo evidenza a favore di un'aggiunta introdotta per convinzione, e la fedeltà alla riproduzione ha la precedenza.

3 · Il transformer

3.1 L'attenzione come dizionario morbido

Un dizionario classico associa a una chiave esatta un valore. L'attenzione generalizza: data una *query* $\mathbf{q}$, invece di cercare la chiave identica si calcola una **similarità** con tutte le chiavi $\mathbf{k}_j$, la si normalizza a distribuzione di probabilità, e si restituisce la *media pesata* dei valori:

$$\text{Attn}(\mathbf{q}, \mathbf{K}, \mathbf{V}) = \hat{\mathcal{E}}_j \hat{\mathcal{I}}_{\pm j} \mathbf{v}_j, \quad \alpha = \text{softmax}(\mathbf{q}^\top \mathbf{K} / \sqrt{d_k}) \quad (3.1)$$

Nella *self-attention* query, chiavi e valori derivano tutte dalla stessa sequenza tramite tre proiezioni lineari apprese. In forma matriciale, per una sequenza $\mathbf{X} \in \mathbb{R}^{n \times d}$:

$$\mathbf{Q} = \mathbf{X} \mathbf{W}_Q, \quad \mathbf{K} = \mathbf{X} \mathbf{W}_K, \quad \mathbf{V} = \mathbf{X} \mathbf{W}_V, \quad \mathbf{A} = \text{softmax}(\mathbf{Q} \mathbf{K}^\top / \sqrt{d_k}), \quad \text{out} = \mathbf{A} \mathbf{V} \mathbf{W}_O \quad (3.2)$$

3.2 Derivazione dello scaling $1/\sqrt{d_k}$

Perché proprio quel fattore? Si assuma che le componenti di $\mathbf{q}$ e $\mathbf{k}$ siano indipendenti, a media nulla e varianza unitaria. Il prodotto scalare è una somma di d_k termini indipendenti:

$$\text{Var}(\mathbf{q}^\top \mathbf{k}) = \text{Var}(\hat{\mathcal{E}}_{i=1}^{d_k} q_i k_i) = \hat{\mathcal{E}}_i \text{Var}(q_i k_i) = d_k \quad (3.3)$$

La deviazione standard dei logit cresce dunque come $\sqrt{d_k}$. Senza correzione, con $d_k = 64$ i logit hanno scala ± 8 e la softmax entra in saturazione: una componente si avvicina a 1, tutte le altre a 0. Il gradiente della softmax è $\partial \alpha_i / \partial z_j = \alpha_i (\delta_{ij} - \alpha_j)$, che nei regimi saturi tende a zero: il gradiente svanisce e l'attenzione non impara più a riallocarsi. Dividere per $\sqrt{d_k}$ riporta la varianza a 1 indipendentemente dalla dimensione.

3.3 Multi-head

Una singola attenzione produce *una* distribuzione di pesi: il modello è costretto a un unico criterio di rilevanza per posizione. Il multi-head suddivide la dimensione d in h sottospazi di dimensione $d_h = d/h$, esegue l'attenzione in parallelo in ciascuno e concatena:

$$\text{MHSA}(\mathbf{X}) = [\text{head}_1 \parallel \dots \parallel \text{head}_h] \mathbf{W}_O, \quad \text{head}_i = \text{Attn}(\mathbf{X} \mathbf{W}_Q^{(i)}, \mathbf{X} \mathbf{W}_K^{(i)}, \mathbf{X} \mathbf{W}_V^{(i)}) \quad (3.4)$$

Il costo totale è invariato rispetto a una singola testa di dimensione d , perché le proiezioni per-testa sono più piccole: è un guadagno di espressività a parità di calcolo.

IL NUMERO DI TESTE È GRATUITO EVIDENZA

Misurato sul nostro modello con $d = 224$: con 4, 7, 8 o 14 teste, **parametri e FLOPs sono identici** (4 899 151 e 0,5742 G in tutti i casi). La scelta è dunque libera e non ha costo. Adottiamo $h = 7$, che dà $d_h = 32$, la dimensione per testa convenzionale in letteratura (contro i 28 di $h = 8$).

3.4 Complessità — la derivazione centrale del progetto

È la formula che giustifica l'intero paper. Per un blocco, sequenza di lunghezza n in dimensione d , con rapporto FFN r :

Operazione	Costo (MAC)	In n
Proiezioni Q, K, V, O	$4nd^2$	lineare
Punteggi QK^T	n^2d	quadratico
Aggregazione AV	n^2d	quadratico
Feed-forward	$2rnd^2$	lineare

$$C(n, d) = (4 + 2r) \cdot n d^2 + 2 \cdot n^2 d \quad (3.5)$$

Il termine quadratico domina quando $n > (2 + r)d$, cioè per $d = 224$ e $r = 4$ quando $n > 1344$.

UNA SOTTIGLIEZZA CHE CAMBIA LA LETTURA DEL PAPER

Le nostre sequenze sono **molto** più corte di quella soglia: 51 frame per il denso, 4 token per lo sparso. In questo regime **domina il termine lineare**, non quello quadratico. Passare da 51 a 4 riduce il termine quadratico di $(51/4)^2 \approx \mathbf{163}$ volte, ma quello lineare — che è quello che conta davvero qui — «solo» di 12,75 volte.

Il paper motiva il lavoro con la complessità $O(N^2)$ della MHSA, ma sul suo stesso regime operativo il guadagno reale viene soprattutto dal termine lineare. Non è un errore, ma è una **imprecisione argomentativa** che vale la pena saper discutere all'orale — ed è la ragione per cui misuriamo i FLOPs invece di dedurli dalla formula.

Parametri, invece, indipendenti da n : $(4 + 2r)d^2$ per blocco, più bias e LayerNorm. Verificato empiricamente: la formula approssima il conteggio reale entro lo 0,4–0,9 %.

3.5 Pre-norm contro post-norm ASSUNZIONE

Vaswani et al. 2017 normalizzano *dopo* il residuo: $x \leftarrow \text{LN}(x + \text{Sublayer}(x))$. Questa forma richiede un warmup del learning rate per non divergere nelle prime iterazioni. La variante **pre-norm** — $x \leftarrow x + \text{Sublayer}(\text{LN}(x))$ — lascia il ramo residuo come strada *pulita* dall'ingresso all'uscita: il gradiente vi scorre senza attraversare alcuna normalizzazione, e il modello si addestra stabile anche senza warmup.

Adottiamo il pre-norm. Il paper non specifica; è pratica standard dal 2020 e riduce il rischio di divergenza in una ricetta che non possiamo tarare a fondo.

3.6 Codifica posizionale e invarianza a permutazioni EVIDENZA

La self-attention è **equivariante alle permutazioni**: permutando le righe di X si permutano identicamente le righe dell'uscita. Se a valle si applica una media (come facciamo), l'equivarianza diventa **invarianza**: il modello non può in linea di principio distinguere l'ordine dei suoi token.

Il paper dichiara che il modello sparso **non usa codifica posizionale**, e la motivazione è corretta: i token latenti non hanno un ordine intrinseco — sono un insieme, non una sequenza. Sul modello *denso* però il paper tace, e lì i token sono frame temporali, che un ordine ce l'hanno.

Lo abbiamo verificato invece di darlo per scontato. Permutando l'asse temporale di un ingresso e confrontando l'uscita mediata:

senza codifica posizionale : variazione massima $2,4 \cdot 10^{-7}$ (rumore di virgola mobile)
 con codifica posizionale : variazione massima $8,3 \cdot 10^{-2}$

Il primo valore è **invarianza esatta**. Questo rende l'esperimento «con e senza» legittimo e informativo: la domanda diventa *quanto conta l'ordine temporale per riconoscere una parola isolata di un secondo*, che è una domanda scientifica genuina e non una formalità.

Implementiamo tre varianti: assente, sinusoidale (Vaswani) e appresa. La sinusoidale usa

$$PE_{(pos, 2i)} = \sin(pos / 10000^{2i/d}), \quad PE_{(pos, 2i+1)} = \cos(pos / 10000^{2i/d}) \quad (3.6)$$

4 · Convoluzione e early convolution

4.1 Aritmetica

Per un asse di dimensione S , kernel K , stride s , padding p e dilatazione $\hat{l}$:

$$S_{\text{out}} = \lfloor (S + 2p - \delta(K-1) - 1) / s \rfloor + 1 \quad (4.1)$$

Applicata al nostro stem, partendo da 64×101 :

```
conv 7x7 stride 2 pad 3   64 -> 32   101 -> 51
maxpool 3x3 stride (2,1) 32 -> 16   51 -> 51
-----
feature map              [C, 16, 51]
```

Il **campo recettivo** cresce come $R_l = R_{l-1} + (K_l - 1) \cdot \Pi_{i < l} s_i$: dopo conv $7 \times 7 / 2$ e maxpool 3×3 , ogni cella dell'uscita vede 11 frame originali, cioè circa 110 ms di segnale — la scala di un fonema.

4.2 Perché la early convolution è indispensabile [DAL PAPER](#)

Il paper è esplicito e la ragione è profonda:

«Gradient computation for region adjustment through bilinear interpolation can be very noisy due to local and limited sampling points. Therefore, directly sampling from the spectrogram is not effective.»

Il campionamento sparso è differenziabile *rispetto alle coordinate* attraverso l'interpolazione bilineare (§7.3). Ma il gradiente rispetto a una coordinata è essenzialmente una **differenza finita locale** della superficie campionata. Su uno spettrogramma grezzo, che ha struttura ad alta frequenza spaziale — armoniche, transienti, rumore — quella differenza è dominata dal rumore locale e non porta informazione utile su *dove* spostare la regione. Dopo qualche convoluzione la superficie è liscia, e il gradiente diventa un segnale di direzione affidabile.

Non è quindi solo una riduzione di risoluzione: è ciò che rende **addestrabile** il meccanismo centrale del paper.

4.3 La sequenza esatta dello stem [EVIDENZA](#)

Il paper descrive «conv 7×7 stride 2 $\rightarrow$ ReLU $\rightarrow$ max pooling», senza normalizzazione. Il codice di SparseFormer conferma e completa:

```
conv1 = nn.Conv2d(in, C, kernel_size=7, stride=2, padding=3, bias=True)
relu  = nn.ReLU(inplace=True)
maxpool = nn.MaxPool2d(3, 2, 1)

x = conv1(x); x = relu(x); x = maxpool(x)
x = layer_norm_by_dim(x, 1)           # LayerNorm sui CANALI, dopo il pooling
```

Tre dettagli che contano:

- la convoluzione ha **bias attivo**, coerentemente con l'assenza di una normalizzazione immediatamente successiva;
- non c'è **alcuna BatchNorm**;
- c'è una **LayerNorm sull'asse dei canali**, applicata *dopo* il max pooling.

UNA NOSTRA DEVIAZIONE, CORRETTA

Una versione precedente del nostro `EarlyConv` inseriva una `BatchNorm2d` fra convoluzione e ReLU, con `bias=False` sulla conv. Era una deviazione su **tre punti**: tipo di normalizzazione sbagliato, posizione sbagliata, bias disattivato.

La differenza fra le due normalizzazioni non è cosmetica. La **BatchNorm** normalizza ciascun canale rispetto al batch e alle posizioni spaziali: le statistiche dipendono dagli altri esempi del batch e vanno congelate in valutazione. La **LayerNorm sui canali** normalizza ogni posizione spaziale rispetto ai propri canali: è indipendente dal batch e si comporta identicamente in training e in inferenza. Per un modello che verrà valutato su costo computazionale e latenza, la seconda è anche più prevedibile.

Coperto ora da un test di regressione che verifica la sequenza esatta dei moduli e l'assenza di `BatchNorm2d`.

5 · Ottimizzazione

5.1 Da SGD ad Adam

La discesa del gradiente stocastica aggiorna $\theta \leftarrow \theta - \eta g_t$ con g_t stima del gradiente su un minibatch. Il **momento** accumula una media mobile della direzione, smorzando le oscillazioni nelle direzioni a curvatura elevata. I metodi **adattivi** aggiungono un secondo ingrediente: riscaldare ogni coordinata in base alla magnitudine storica del suo gradiente, così che parametri con gradienti tipicamente piccoli ricevano passi relativamente maggiori.

Adam combina i due:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2)g_t^2 \quad (5.1)$$

LA CORREZIONE DEL BIAS, DERIVATA

Inizializzando $m_0 = 0$, si espande la ricorsione:

$$m_t = (1-\beta_1) \sum_{i=1}^t \beta_1^{t-i} g_i \quad (5.2)$$

Se i gradienti fossero stazionari con media g , si avrebbe $\mathbb{E}[m_t] = g(1-\beta_1)\sum_{i=1}^t \beta_1^{t-i} = g(1 - \beta_1^t)$. La stima è dunque **distorta verso zero** di un fattore $(1 - \beta_1^t)$, grave nei primi passi: con $\beta_1 = 0,9$ al primo passo il momento vale un decimo del vero. Da cui la correzione:

$$\hat{m}_t = m_t / (1-\beta_1^t), \quad \hat{v}_t = v_t / (1-\beta_2^t), \quad \theta \leftarrow \theta - \eta \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) \quad (5.3)$$

5.2 AdamW: perché L2 e weight decay non coincidono

È la domanda d'esame più probabile su questo blocco.

Nella discesa del gradiente *semplice*, aggiungere alla loss il termine $\lambda/2 \cdot \|\theta\|^2$ produce nel gradiente il contributo $\lambda\theta$, e quindi l'aggiornamento $\theta \leftarrow (1 - \eta\lambda)\theta - \eta g$: un decadimento moltiplicativo uniforme. Regolarizzazione L2 e weight decay **coincidono**.

In Adam no. Il termine $\lambda\theta$ entra dentro g_t , quindi viene **diviso per $\sqrt{\hat{v}_t}$** come ogni altra componente del gradiente. Il risultato è che il decadimento effettivo di ciascun peso diventa $\eta\lambda\theta/(\sqrt{\hat{v}_t} + \epsilon)$: **i parametri con gradienti storicamente grandi vengono regolarizzati di meno**, quelli con gradienti piccoli di più. È l'opposto di ciò che si vuole, ed è un effetto non voluto e difficile da controllare.

Loshchilov & Hutter (2018) propongono di **disaccoppiarlo**: applicare il decadimento direttamente ai pesi, fuori dal percorso adattivo:

$$\theta \leftarrow \theta - \eta (\hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon) + \lambda \theta) \quad (5.4)$$

Entrambi i paper usano AdamW. Noi con $\beta = (0,9 \cdot 0,99)$, $\epsilon = 10^{-8}$, $\eta = 3 \cdot 10^{-4}$, $\lambda = 10^{-5}$ DAL PAPER.

WEIGHT DECAY SELETTIVO: NON È UNA NOSTRA AGGIUNTA EVIDENZA

Avevamo classificato come *nostra deviazione* l'esclusione di bias e parametri di normalizzazione dal weight decay. **Era una classificazione sbagliata.** Il `trainer.py` di EAT costruisce l'ottimizzatore con `weight_decay=0` e delega la regolarizzazione a gruppi di parametri creati da `add_weight_decay`, il cui criterio è:

```
if len(param.shape) == 1: # nessun weight decay
```

Ogni parametro monodimensionale è escluso: bias di convoluzioni e linear, pesi e bias di LayerNorm e BatchNorm. Il criterio è più semplice e più generale di «bias e norm», e li cattura tutti.

Poiché Kavaki & Mandel riprendono la ricetta di EAT alla lettera — stesso lr $3 \cdot 10^{-4}$, stessi β , stesso one-cycle, stesso EMA 0,995, stesso weight decay 10^{-5} , stesse augmentation — la lettura più difendibile è che abbiano ereditato anche questo. Da deviazione a **scelta conforme al riferimento**.

La motivazione teorica resta quella di prima: spingere verso zero un parametro di scala di normalizzazione non ha senso statistico, perché non controlla la complessità del modello ma la sua parametrizzazione interna.

5.3 One-cycle DAL PAPER

Il learning rate sale da $\hat{l}_{\max}/\text{div}$ fino a $\hat{l}_{\max}$ nella prima frazione del training, poi scende fino a un valore molto piccolo. La fase crescente agisce come warmup ed esplora ampiamente il paesaggio; quella decrescente rifinisce. Smith (2018) argomenta che il learning rate elevato in mezzo funge da regolarizzatore, scoraggiando i minimi stretti.

Il paper cita lo schedule ma non ne dà i parametri. Li abbiamo presi dal `trainer.py` di EAT EVIDENZA:

Parametro	Valore	Fonte
<code>max_lr</code>	$3 \cdot 10^{-4}$	dichiarato da entrambi i paper
<code>pct_start</code>	0,1	esplicito nel trainer di EAT — il 10 % del training è salita
<code>div_factor</code>	25	default PyTorch, non sovrascritto da EAT → lr iniziale $1,2 \cdot 10^{-5}$
<code>final_div_factor</code>	10^4	default PyTorch → lr finale $1,2 \cdot 10^{-9}$

Restano non fissate da nessuna fonte le **epoche**: è l'unico iperparametro di training che dobbiamo scegliere noi.

5.4 Media mobile esponenziale dei pesi DAL PAPER

$$\theta^{\text{EMA}} \leftarrow \gamma \theta^{\text{EMA}} + (1-\gamma) \theta, \quad \gamma = 0,995 \quad (5.5)$$

Con $\gamma = 0,995$ la costante di tempo è circa $1/(1-\gamma) = 200$ passi. L'EMA media la traiettoria SGD nelle sue ultime centinaia di iterazioni, riducendo la varianza dovuta al rumore dei minibatch e tendendo a finire in regioni più piatte del paesaggio, che generalizzano meglio. **Il modello che si valuta è quello EMA**: dimenticarlo costa tipicamente qualche decimo di punto.

Verificato nei test: con decay 0,9, spostando i pesi di +1,0 l'EMA si sposta esattamente di $1 - \gamma = 0,1$.

6 · Loss e augmentation

6.1 Il gradiente della cross-entropy con softmax

Sia $\mathbf{z}$ il vettore dei logit, $p_i = e^{z_i} / \sum_j e^{z_j}$ e $L = -\sum_i y_i \log p_i$. Dalla derivata della softmax $\partial p_i / \partial z_j = p_i (\delta_{ij} - p_j)$:

$$\partial L / \partial z_j = \sum_i (-y_i / p_i) \cdot p_i (\delta_{ij} - p_j) = p_j \sum_i y_i - y_j = p_j - y_j \quad (6.1)$$

La forma $\mathbf{p} - \mathbf{y}$ è il motivo per cui softmax e cross-entropy si usano insieme: la composizione dà il gradiente più semplice possibile, e non satura come farebbe una MSE su una sigmoide.

IL TRUCCO LOG-SUM-EXP

Calcolare e^{z_i} direttamente trabocca per $z_i \hat{=} 88$ in float32. Sfruttando l'invarianza della softmax per traslazione dei logit si sottrae il massimo:

$$\log \sum_i e^{z_i} = z_{\max} + \log \sum_i e^{z_i - z_{\max}} \quad (6.2)$$

Tutti gli esponenti sono ora ≤ 0 e nessuno trabocca. È ciò che fanno internamente `log_softmax` e `BCEWithLogitsLoss`: motivo per cui si passa loro i *logit* e non le probabilità.

6.2 Perché BCE con target mixati

Mixing e phasemix producono target del tipo $y = \lambda y_1 + (1-\lambda) y_2$, cioè distribuzioni con due componenti non nulle. La cross-entropy con softmax su un target del genere **non è più il log-likelihood di alcun modello generativo**: la softmax modella una variabile categoriale con esito unico, e l'esempio mixato non ha un esito unico.

Entrambi i paper usano quindi la **binary cross-entropy**, che tratta le 35 uscite come 35 problemi binari indipendenti:

$$L = -(1/C) \sum_c [y_c \log \sigma(z_c) + (1-y_c) \log(1-\sigma(z_c))] \quad (6.3)$$

Qui $y_c \in [0,1]$ è perfettamente sensato come *probabilità marginale* che la classe c sia presente — e nulla obbliga la somma su c a fare 1. È proprio questa libertà che permette il target **multi-hot** di §6.3.4, dove un esempio mixato dichiara la presenza di due parole.

Nel nostro codice la BCE è il **percorso unico**: anche senza augmentation i target sono one-hot in forma $[B, C]$, così il ramo di loss non cambia mai. Verificato nei test: i target contengono solo valori 0 o 1, con una o due classi attive per campione.

6.3 Le due augmentation di Kavaki & Mandel EVIDENZA

Il paper dichiara di usare «mixing and phasemix augmentation [1]», cioè due tecniche di EAT. EAT le descrive con **una riga di testo ciascuna**, senza formule. Le abbiamo ricavate dal codice ufficiale (`datasets/batch_augs.py`), e nessuna delle due è quello che il nome suggerisce.

6.3.1 MIXING NON È IL MIXUP DI ZHANG ET AL.

È il **between-class learning** di Tokozume et al. 2017 — che EAT cita come [14] e che noi avevamo in bibliografia senza collegarlo. I due segnali non vengono interpolati linearmente: vengono bilanciati in base al loro **livello sonoro**, e il risultato viene rinormalizzato in energia.

$$G_i = 10 \log_{10} \mathbb{E}[x_i^2] \quad (\text{livello in dB}) \quad (6.4)$$

$$p = 1 / (1 + 10^{(G_1 - G_2)/20} \cdot (1 - \lambda) / \lambda) \quad (6.5)$$

$$x = (p x_1 + (1 - p) x_2) / \sqrt{p^2 + (1 - p)^2}, \quad y = \lambda y_1 + (1 - \lambda) y_2 \quad (6.6)$$

Tre osservazioni sul perché è costruito così:

- **il peso dei dati non è il peso delle etichette:** i campioni si mescolano con p , corretto per il livello, mentre le etichette con λ , che è il rapporto *perceptivo* voluto. Se x_1 è molto più forte di x_2 , servono pesi diseguali per ottenere una miscela percettivamente bilanciata;
- la divisione per $\sqrt{p^2 + (1 - p)^2}$ **mantiene costante l'energia attesa**. Senza, il volume della miscela diventerebbe un indizio dell'avvenuta augmentation, e il modello potrebbe imparare a sfruttarlo invece che a generalizzare;
- $\lambda \sim \text{Uniform}[0, 1]$, non una Beta.

6.3.2 PHASEMIX PRESERVA L'AMPIEZZA, NON LA MESCOLO

La descrizione di EAT — «mixes phase components *while preserving amplitude*» — va letta alla lettera: l'ampiezza **non si mescola affatto**. Si prende quella di un campione e solo la fase dell'altro.

$$\mathbf{X} = \text{STFT}(x_1), \quad \varphi = \lambda \angle \mathbf{X}_1 + (1 - \lambda) \angle \mathbf{X}_2, \quad x = \text{iSTFT}(|\mathbf{X}_1| \cdot e^{j\varphi}) \quad (6.7)$$

$$\text{peso dell'etichetta} = \lambda \cdot 0,5 + 0,5 \in [0,5 \cdot 1], \quad \lambda \sim \text{Uniform}[0, 1] \quad (6.8)$$

IL PESO DELL'ETICHETTA È LA FINEZZA CHE NON SI POTEVA INDOVINARE

Mescolare la sola fase altera il segnale *meno* di quanto faccia mescolare tutto: è giusto che l'etichetta resti più vicina all'originale. Il rimappaggio $\lambda \mapsto \lambda/2 + 1/2$ fa esattamente questo, e garantisce che il peso della classe originale **non scenda mai sotto 0,5**. Nessuna descrizione testuale avrebbe potuto suggerirlo.

Le fasi sono interpolate **sugli angoli**, non sui vettori unitari. È una scelta discutibile — l'interpolazione lineare attraversa la discontinuità a $\pm\pi$ — ma qui conta la fedeltà al riferimento, non il miglioramento del metodo. Una nostra prima versione usava i vettori unitari e mescolava anche le ampiezze: era sbagliata su entrambi i fronti.

6.3.3 CONSISTENZA DELLA STFT: UNA PROPRIETÀ NON OVVIA EVIDENZA

«AMPIEZZA PRESERVATA» VALE SULLA MATRICE, NON SUL SEGNALE

Una matrice complessa arbitraria **non è, in generale, la STFT di alcun segnale reale**. Con finestre sovrapposte — qui al 60 %, finestra 400 e hop 160 — i frame adiacenti condividono campioni e quindi si vincolano a vicenda. Alterare le fasi rompe quel vincolo e rende la matrice *inconsistente*.

La iSTFT esegue overlap-add, che equivale a **proiettare sul sottospazio delle STFT consistenti**. Quella proiezione cambia anche i moduli: misurato, un errore relativo medio di circa il **34 %** ricalcolando la STFT del segnale ricostruito.

Non è un difetto dell'implementazione — è una proprietà del metodo, ed è plausibilmente parte di ciò che lo rende efficace come augmentation: il segnale prodotto non è una semplice ricombinazione dei due originali. È lo stesso fenomeno che rende necessari algoritmi come Griffin-Lim per la ricostruzione da spettrogrammi di sola ampiezza.

Due test fissano entrambi i lati: con $\lambda=1$ la funzione è l'identità entro 10^{-4} (correttezza del percorso STFT→iSTFT), e con $\lambda=0$ la deviazione dei moduli è misurabile ma limitata.

6.3.4 IL TARGET NON È MORBIDO: È MULTI-HOT EVIDENZA

Questa è l'ultima e più sottile delle correzioni. Avevamo scritto che i target sono $\lambda y_1 + (1-\lambda)y_2$, cioè distribuzioni pesate. Il ramo 'bce' di `mix_loss` in EAT fa un'altra cosa:

```
target          = F.one_hot(target, n_classes).float()
target_shuffled = F.one_hot(target_shuffled, n_classes).float() * (lam < 0.9)
one_h_mix       = torch.clamp(target + target_shuffled, max=1)
loss            = self.loss(logits, one_h_mix)
```

$$y = \min(y_1 + y_2 \cdot \mathbb{1}[\lambda < 0.9], 1) \quad (6.9)$$

Tre osservazioni, tutte importanti:

- **λ non è un peso, è una soglia.** Non compare nel valore del target ma solo nella decisione se includere o no la seconda etichetta. Se $\lambda \geq 0.9$ il secondo suono è troppo debole per essere udibile e la sua etichetta viene scartata.
- **Il target è multi-hot:** entrambe le classi valgono 1, non λ e $1-\lambda$. È la formulazione naturale per la BCE, che tratta ogni classe come una domanda binaria indipendente — «questa parola è presente?» — e la risposta per una miscela udibile di due parole è sì a entrambe.
- Il `clamp` serve al caso in cui i due campioni appartengano alla **stessa classe**, che altrimenti darebbe un target pari a 2.

PERCHÉ LA NOSTRA PRIMA FORMULAZIONE ERA COMUNQUE COERENTE — MA CON L'ALTRO RAMO

EAT ha due modalità. Il ramo 'ce' combina due loss come $\lambda L_1 + (1-\lambda)L_2$, che per linearità della cross-entropy nel target è equivalente a un target morbido $\lambda y_1 + (1-\lambda)y_2$. Il ramo 'bce', quello che si usa col mixing, fa invece il multi-hot con soglia.

Avevamo implementato la semantica del ramo sbagliato. Non è un errore di equivalenza matematica ma di scelta del riferimento, ed è il tipo di dettaglio che si vede solo leggendo il codice.

Nota sull'implementazione: `randperm` ha **punti fissi**, quindi circa $1/B$ dei campioni per batch viene mixato con sé stesso e il clamp riporta il target a una sola classe. È il comportamento del riferimento, non un difetto — ma va saputo, perché fa fallire i test scritti assumendo che tutti i target mixati abbiano due classi attive.

6.3.5 COME SONO PROGRAMMATE LE AUGMENTATION EVIDENZA

Il paper dice solo «we also employed data augmentation techniques, including mixing and phasemix». La logica di dispatch viene da `BatchAugs.__call__`:

```
se augs non vuoto e rand() <= mix_ratio e epoch > epoch_mix:
    scegli UNA augmentation a caso e applicala all'INTERO batch
```

- `mix_ratio` è la probabilità di mescolare, e il **default di EAT è 1** — cioè *sempre*. Avevamo assunto 0,5: sbagliato;
- `epoch_mix` è una soglia di epoca sotto la quale il mixing è disattivato, utile per far partire il training su dati puliti;
- una sola augmentation per batch, scelta a caso, applicata a **tutto** il batch — non a un sottoinsieme di campioni.

7 · Il metodo sparso, per intero

7.1 L'idea

Invece di dare al transformer tutti i frame temporali, gli si danno N **token latenti**, ciascuno accoppiato a una **regione** del piano tempo-frequenza da cui estrae informazione. Token e regioni iniziali sono **parametri del modello**, appresi: il modello impara *dove guardare*, non solo *cosa farne*. Il processo si ripete L_{rep} volte, raffinando a ogni giro regioni, punti campionati e token.

Configurazione dichiarata: $N = 4$ token, $P = 36$ campioni per token, $d_{\text{token}} = 64$, $d_{\text{enc}} = 128$, $L_{\text{rep}} = 3$, $L_{\text{enc}} = 8$

[DAL PAPER](#).

INIZIALIZZAZIONE EVIDENZA

Il paper dice: «we initialize the center of the regions to a grid and the width and height of them to half of the feature dimension». Il codice di SparseFormer dà la forma precisa:

```
nn.init.trunc_normal_(token_embedding.weight, std=1.)

root = sqrt(N)
grid = arange(root) / (root - 1)          # [0, 1] uniforme
token_roi[..., 0:2] = grid * (1 - unit_width) # angolo in basso a sinistra
token_roi[..., 2:4] = grid * (1 - unit_width) + unit_width
```

I token si inizializzano da una normale troncata con deviazione 1; le regioni su una griglia regolare in coordinate normalizzate $[0, 1]$, con lato `unit_width` (0,5 secondo il paper). Le regioni sono memorizzate come $(\mathbf{x}_1, \mathbf{y}_1, \mathbf{x}_2, \mathbf{y}_2)$ — angoli opposti — e centro e dimensione si ricavano al volo; le equazioni (7.2) restano identiche.

UNA CONSEGUENZA CHE SPIEGA UN DETTAGLIO DEL PAPER

La griglia è $\text{root} \times \text{root}$ con $\text{root} = \sqrt{N}$. Da qui segue che **N deve essere un quadrato perfetto** — ed è esattamente quello che si osserva nella Tabella 3 del paper, la cui ablation usa $N \in \{4, 9, 16, 25, 36\}$. Non è una scelta estetica degli autori: è un vincolo strutturale ereditato da SparseFormer.

È il tipo di dettaglio che, notato e spiegato all'orale, dimostra di aver capito il metodo e non solo letto il paper.

7.2 Passo 1 — aggiustamento delle regioni

Una regione è $b = (x, y, w, h)$. Il token produce quattro numeri tramite uno strato lineare, e questi aggiornano la regione:

$$(t_x, t_y, t_w, t_h) = \text{Linear}(t) \quad (7.1)$$

$$x' = x + t_x \cdot w, \quad y' = y + t_y \cdot h, \quad w' = w \cdot e^{t_w}, \quad h' = h \cdot e^{t_h} \quad (7.2)$$

PERCHÉ L'ESPONENZIALE — DOMANDA D'ESAME QUASI CERTA

Tre ragioni, tutte necessarie.

Positività. Larghezza e altezza devono restare positive. $w \cdot e^t$ lo garantisce per costruzione, per qualunque valore reale prodotto dalla rete; una forma additiva $w + t$ richiederebbe un clamp, che azzerà il gradiente quando è attivo.

Invarianza di scala. L'aggiornamento è moltiplicativo: lo stesso t_w raddoppia una regione piccola e una grande. La rete apprende *rapporti*, non incrementi assoluti, ed è la parametrizzazione naturale per una quantità positiva.

Simmetria. t_w e $-t_w$ producono fattori reciproci: allargare e restringere costano lo stesso nello spazio dei parametri. Con la forma additiva no.

Anche gli spostamenti sono *relativi* alla dimensione della regione ($t_x \cdot w$): una regione grande si sposta di più a parità di segnale. Tutto questo viene da Faster R-CNN.

7.3 Passo 2 — campionamento sparso

Ogni token genera P offset relativi, poi mappati in coordinate assolute dentro la propria regione:

$$\{(\hat{I}^x x_i, \hat{I}^y y_i)\}_{i=1..P} = \text{Linear}(\text{LayerNorm}(t)) \quad (7.3)$$

$$\tilde{x}_i = x + 0,5 \cdot \Delta x_i \cdot w, \quad \tilde{y}_i = y + 0,5 \cdot \Delta y_i \cdot h \quad (7.4)$$

Il fattore 0,5 mappa $\Delta \in [-1, 1]$ esattamente sull'estensione della regione.

LA NORMALIZZAZIONE «A TRE DEVIAZIONI STANDARD» EVIDENZA

Il paper scrive: «To make sure that most of the sampled points fall inside of the region, we need to do normalization over the relative offsets by three standard deviations», senza formula. Il codice di SparseFormer la fornisce:

```
offset_mean = relative_offset_xy.mean(-2, keepdim=True)
offset_std = relative_offset_xy.std(-2, keepdim=True) + 1e-7
relative_offset_xy = (relative_offset_xy - offset_mean) / (3 * offset_std)
```

Media e deviazione sono calcolate **sull'asse dei P punti**, cioè fra i campioni di uno stesso token, non sul batch. L'operazione è quindi una standardizzazione dell'*insieme* di offset generati, seguita da una divisione per 3.

Il senso è geometrico: dopo la standardizzazione gli offset hanno media 0 e deviazione 1; dividendo per 3 la deviazione diventa $1/3$, e per una distribuzione approssimativamente normale circa il **99,7 %** della massa cade in $[-1, 1]$ — cioè, dopo il riscaldamento di (7.4), dentro la regione. È la regola dei tre sigma, applicata per costruzione invece che sperando che accada.

Nota implementativa: standardizzare fra i punti significa che il modello controlla la *forma* della nuvola di campionamento, mentre la sua posizione e dimensione restano governate dalla regione. I due meccanismi sono disaccoppiati, il che spiega perché servano entrambi.

INTERPOLAZIONE BILINEARE E SUO GRADIENTE

Le coordinate sono continue, la feature map è discreta. Detto $(\tilde{x}, \tilde{y})$ con parte intera (x_0, y_0) e frazionaria (a, b) :

$$F(\tilde{x}, \tilde{y}) = (1-a)(1-b)F_{00} + a(1-b)F_{10} + (1-a)b F_{01} + ab F_{11} \quad (7.5)$$

È il meccanismo che rende **differenziabile la selezione**. Derivando rispetto alla coordinata:

$$\partial F / \partial \tilde{x} = (1-b)(F_{10} - F_{00}) + b(F_{11} - F_{01}) \quad (7.6)$$

cioè una **differenza finita locale** fra celle adiacenti. Da qui discendono due fatti fondamentali:

- il gradiente vede solo le **4 celle adiacenti**: è cieco a tutto ciò che sta oltre un pixel di distanza, quindi la regione può muoversi solo per piccoli passi seguendo la pendenza locale;
- se la superficie è ruvida, quella differenza è **rumore**. È esattamente la ragione per cui serve la early convolution (§4.2). Il legame fra i due paragrafi è il cuore tecnico del paper.

7.4 Passo 3 — decoding adattivo

Ora si hanno P vettori di feature campionati, $x^{(0)} \in \mathbb{R}^{P \times C}$, e vanno compressi nel token. Il paper nota che «simply using a linear layer for this encoding is not effective». La soluzione, ereditata da AdaMixer, è generare i pesi di mixing **dal token stesso**:

$$[\mathbf{M}_c \mid \mathbf{M}_s] = F(t), \quad \mathbf{M}_c \in \mathbb{R}^{C \times C}, \quad \mathbf{M}_s \in \mathbb{R}^{P \times P} \quad (7.7)$$

$$x^{(1)} = \text{GELU}(x^{(0)} \mathbf{M}_c), \quad x^{(2)} = \text{GELU}(\mathbf{M}_s x^{(1)}), \quad t' = t + \text{Linear}(x^{(2)}) \quad (7.8)$$

LA DIFFERENZA CONCETTUALE FRA PESI FISSI E PESI CONDIZIONATI

Uno strato lineare ordinario applica **gli stessi pesi** a tutti gli input: impara una trasformazione media, buona in media per tutti i token. Qui invece $\mathbf{M}_c$ e $\mathbf{M}_s$ sono **funzioni del token**: ogni token specifica come vuole mescolare i propri campioni. Un token che sta seguendo una regione di bassa frequenza può pesare i canali diversamente da uno su un transiente.

È lo stesso principio delle *hypernetwork* e dei meccanismi di attenzione: la rete genera parte dei propri pesi in funzione del contesto. Il costo si vede nel conteggio dei parametri, perché F deve produrre $C^2 + P^2$ valori.

L'aggiornamento del token è **residuo** ($t' = t + \dots$), come nei blocchi transformer: il token accumula informazione a ogni ripetizione invece di essere riscritto, e il gradiente ha un percorso diretto verso i parametri iniziali.

7.5 Il transformer di classificazione

Gli N token finali entrano in 8 blocchi encoder, **senza codifica posizionale**, poi media e classificatore lineare. Con $N = 4$ la matrice di attenzione è 4×4 : praticamente gratuita.

7.6 Contare i FLOPs di questo modello

ATTENZIONE: GRID_SAMPLE NON VIENE CONTATO

L'interpolazione bilineare è un'operazione di *gather* più combinazione lineare: non contiene alcun prodotto matriciale, quindi **né il contatore nativo di torch né fvcore la vedono**. Sul modello sparso questo significa sottostimare proprio il meccanismo che si vuole difendere.

Va aggiunta a mano. Per punto e canale servono 4 letture pesate e 3 somme, più circa 4 operazioni per i pesi condivisi fra canali: `grid_sample_flops(P, C) = P * (4 + 7C)`. È implementata in `src/flops.py`.

8 · La ricostruzione del modello denso

8.1 Il problema

Del dense-transformer il paper fornisce **due soli numeri**: 4,80 M parametri e 0,645 G FLOPs. Nessun iperparametro. Assemblare secondo la Tabella 1 — che descrive lo *sparso* — dà circa 1,8 M: un fattore 2,7 di scarto.

8.2 Il metodo: i numeri come vincoli

Quei due numeri sono **vincoli**. Non tutte le combinazioni delle scelte libere li soddisfano, quindi si può cercare nello spazio delle configurazioni e tenere quelle compatibili — un lavoro di minuti di CPU, senza addestrare nulla. I gradi di libertà considerati:

Grado di libertà	Valori esplorati
Lettura dei canali	<code>c96</code> · <code>c196</code> · <code>c196_proj96</code> (196 kernel poi proiezione a 96)
Stem	<code>paper</code> (conv 7×7 singola) · <code>xiao</code> (stack 3×3)
Stride del pooling	(2,2) → $N=26$ · (2,1) → $N=51$
Formazione della sequenza	<code>flatten</code> · <code>pool_freq</code> · <code>patches2d</code>
Dimensione d	128 ... 288
Profondità	$6 \cdot 8 \cdot 12$

8.3 Risultato 1 — il pooling agisce solo sulla frequenza EVIDENZA

Su 432 configurazioni, **tutte quelle vicine al costo dichiarato hanno $N = 51$** . La famiglia $N = 26$ si ferma a 0,451 G contro 0,645, uno scarto del 30 % che nemmeno lo stem convolutivo più pesante recupera.

Il paper dice solo «max pooling», senza stride. Ne deduciamo che **deve preservare la risoluzione temporale** — un dettaglio non scritto da nessuna parte, ricavato da due numeri.

8.4 Risultato 2 — il paper riporta FLOPs, non MAC EVIDENZA

Ogni configurazione che si avvicina a 0,645 lo fa nella colonna *FLOP* (0,53–0,66); i MAC corrispondenti stanno a 0,26–0,33, cioè metà. Il paper usa dunque la convenzione del contatore nativo di torch.

Il rapporto esatto di 2 fra le due convenzioni è verificato da un test dedicato: su un `Linear(100→200)` senza bias, fvcore riporta 20 000 e torch 40 000. Questa calibrazione rende legittimi tutti i confronti successivi con i numeri pubblicati.

8.5 Un errore di metodo, e la sua correzione

AVEVAMO LASCIATO LIBERA LA PROFONDITÀ

La prima ricerca trattava L come incognita e sceglieva $L = 6$, che fitta i parametri a +0,0 %. Ma il paper dichiara **8 transformer-encoder** per lo sparso e descrive il denso come «*the same architecture but processes a sequence of time frames*»: la profondità **era data**.

Ottimizzare un parametro già vincolato è l'errore classico del fitting. Imponendo $L = 8$ si perdono due punti percentuali sui parametri e si guadagna coerenza col testo — che all'esame vale incomparabilmente di più.

8.6 Un'ipotesi formulata e confutata EVIDENZA

Restava uno scarto di circa l'11 % sul costo. Ipotesi: il paper scrive «convolutional layers» al plurale, quindi gli strati sono più di uno e il costo mancante viene da lì. **Testata:**

n. conv	parametri	errore	GFLOP	errore
1	4 899 151	+2,1 %	0,574	-11,0 %
2	5 245 287	+9,3 %	1,703	+164 %
3	5 591 423	+16,5 %	2,831	+339 %

Ipotesi confutata, e nettamente. Una convoluzione 3×3 con 196 canali alla risoluzione piena (32×51) costa da sola più di 1 GFLOP: aggiungere strati non colma lo scarto, lo travolge. Lo scarto dell'11 % resta **non spiegato**, e va riportato come tale.

8.7 La configurazione adottata

lettura canali	c196_proj96	196 kernel poi proiezione 1x1 a 96
stem	paper	una conv 7x7 stride 2, ReLU, maxpool
pool stride	(2, 1)	solo sull'asse frequenza -> $N = 51$
sequenza	pool_freq	media sulla frequenza, $N = T$
dimensione	$d = 224$	
profondita'	$L = 8$	dichiarata dal paper
teste	$h = 7$	$d_h = 32$

parametri	4.899.147	dichiarati 4,80 M -> +2,1 %
costo	0,574 GFLOP	dichiarati 0,645 -> -11,0 %

Si addestra **anche** la variante `flatten`, che fitta meglio il costo (-5,9 %) ma peggio i parametri: le due bracketizzano l'incertezza. `pool_freq` resta la scelta meno sicura di tutte, perché media via la struttura in frequenza proprio nel baseline che verrà confrontato con un modello che campiona nel piano tempo-frequenza.

PERCHÉ CI FERMIAMO QUI

Nessuna configurazione soddisfa *entrambi* i vincoli, e i due tirano in direzioni opposte. Continuare ad aggiungere gradi di libertà finché i numeri combaciano significherebbe fare **overfitting su una cifra riportata senza convenzione dichiarata**, in un paper che nello stesso paragrafo si contraddice. Un accordo ottenuto così non sarebbe una verifica ma una tautologia.

La posizione difendibile è: parametri entro il 2 %, costo entro l'11 %, un'ipotesi sul residuo formulata e confutata, tutto dichiarato.

9 · Catalogo delle assunzioni

Ogni riga è un punto su cui il paper tace o si contraddice. La colonna «stato» dice se abbiamo evidenza a supporto.

Punto	Scelta	Stato
Parametri spettrogramma	log-mel, 25/10 ms, 64 bin	EVIDENZA sonda lineare: escursione di 0,8 punti su un fattore 4 di risoluzione, curva non monotona. 64 bin sono a 0,22 punti dal migliore e danno $F=16$ dopo lo stem.
Normalizzazione per-campione	disattivata ; flag per ablation	EVIDENZA contraria : la sonda peggiora di 0,5 punti, benché l'escursione di livello nei dati sia di 28,5 dB. Né il paper né i due ancestor la usano.
Normalizzazione nello stem	LayerNorm sui canali dopo il pooling	EVIDENZA sequenza esatta dal codice di SparseFormer. La BatchNorm che avevamo inserito era una deviazione su tre punti: layer, posizione e bias della conv.
Formula di <code>mixing</code>	between-class con correzione di potenza	EVIDENZA dal codice di EAT. Non è il mixup di Zhang et al., come il nome faceva supporre.
Formula di <code>phasemix</code>	STFT, ampiezza preservata, fasi sugli angoli, peso $\frac{1}{2} + \frac{1}{2}$	EVIDENZA dal codice di EAT. La nostra prima versione, dedotta dal testo, era sbagliata su cinque dettagli su cinque.
Parametri STFT di <code>phasemix</code>	400 / 160, come il front-end	ASSUNZIONE EAT non li dichiara.
Normalizzazione degli offset «a tre deviazioni standard»	standardizzazione sull'asse dei punti, poi divisione per 3	EVIDENZA formula esatta dal codice di SparseFormer.
Inizializzazione di token e regioni	trunc-normal std 1; griglia $\sqrt{N} \times \sqrt{N}$	EVIDENZA dal codice di SparseFormer. Spiega perché nel paper N è sempre un quadrato perfetto.
Contraddizione 96 / 196	<code>c196_proj96</code>	EVIDENZA è la lettura in cui entrambe le cifre sono vere, ed è in testa alla ricerca.
Stride del max pooling	$(2, 1) \rightarrow N = 51$	EVIDENZA forzato dal vincolo di costo; la famiglia $N=26$ sbaglia del 30 %.
Formazione della sequenza	<code>pool_freq</code> + <code>flatten</code>	ASSUNZIONE la meno sicura. Si addestrano entrambe.
Numero di teste	$h = 7, d_h = 32$	EVIDENZA parametri e FLOPs identici per 4/7/8/14 teste: scelta libera, si prende la convenzionale.
Pre-norm	pre-norm	ASSUNZIONE standard dal 2020; evita il warmup.
Codifica posizionale nel denso	da ablare	EVIDENZA l'invarianza a permutazioni è verificata: la domanda è ben posta.
Weight decay su parametri 1D	escluso	EVIDENZA criterio <code>len(shape)==1</code> dal trainer di EAT. Non una nostra aggiunta, come avevamo classificato.
Parametri di one-cycle	<code>pct_start 0,1; div 25; final_div 10</code>	EVIDENZA dal trainer di EAT (gli ultimi due sono i default PyTorch, non sovrascritti).

Punto	Scelta	Stato
Programmazione delle augmentation	<code>mix_ratio = 1</code> , una a caso su tutto il batch	EVIDENZA da <code>BatchAugs.__call__</code> . Avevamo assunto probabilità 0,5: il default è <i>sempre</i> .
Costruzione del target mixato	multi-hot con soglia $\hat{I} \ll 0,9$	EVIDENZA ramo <code>'bce'</code> di <code>mix_loss</code> . Avevamo implementato la semantica del ramo <code>'ce'</code> .
Mel o spettrogramma lineare	mel	EVIDENZA KWT e AST, più la comparazione citata da EAT. <i>Non</i> giustificato da EAT, che usa la forma d'onda grezza.
Label smoothing	assente	ASSUNZIONE EAT usa 0,1 nel ramo CE; con la BCE multi-hot non si applica e Kavaki tace.
Numero di epoche	da fissare	ASSUNZIONE l'unico iperparametro di training che nessuna fonte fissa.

COME È CAMBIATO QUESTO CATALOGO

Prima di leggere il codice degli ancestor questa tabella era quasi tutta **ASSUNZIONE**, e tre delle nostre scelte erano deviazioni non riconosciute. Le due letture successive di `SparseFormer`, `batch_augs.py`, `trainer.py` e `helper_funcs.py` hanno **convertito nove assunzioni in evidenze**, corretto quattro implementazioni sbagliate e **riabilitato una scelta** che avevamo erroneamente classificato come deviazione.

Resta una sola assunzione senza appiglio in nessuna fonte: **il numero di epoche**. Tutto il resto è o dichiarato dal paper, o documentato nel codice di riferimento, o supportato da una nostra misura.

9.1 Che cosa non sappiamo, e non sapremo

Onestà intellettuale richiede di separare ciò che abbiamo risolto da ciò che resta genuinamente aperto.

Questione aperta	Stato
Lo scarto dell'11 % sui FLOPs	Non spiegato. Eliminati due candidati: strati convolutivi aggiuntivi (danno +164 %) e il front-end tempo-frequenza (vale lo 0,8 % del modello). Restano combinazioni di d e L diverse o una formazione della sequenza diversa. Si riporta come tale.
<code>pool_freq</code> contro <code>flatten</code>	Indecidibile dai vincoli: la prima fitta meglio i parametri, la seconda il costo. Si addestrano entrambe e si riportano affiancate.
Pre-norm contro post-norm	Il paper non descrive l'interno degli encoder. Cita Vaswani, che è post-norm; noi usiamo pre-norm. Reso configurabile, da ablare.
Numero di epoche	Nessuna fonte. Si fissa un budget, si dichiara, si verifica la convergenza sulle curve.
Consistenza dei numeri dello sparso	Il conteggio dei parametri torna a -0,8 %, ma i FLOPs dello sparso (0,055 G) non sono ancora stati verificati: è il terzo vincolo indipendente e testerebbe la deduzione <code>pool_stride=(2,1)</code> , che il conteggio dei parametri non tocca. Rimandato alla Fase 4.

10 · Il codice, file per file

10.1 `src/data/speech_commands.py`

Download, verifica MD5, estrazione, costruzione degli split ufficiali e della cache.

La funzione centrale è `build_splits()`, che **solleva un'eccezione** se i conteggi non sono esattamente 84 843 / 9 981 / 11 005. Non è pedanteria: sono i numeri dichiarati dal paper e coincidono con gli elenchi ufficiali `validation_list.txt` e `testing_list.txt`, costruiti sull'hash dello speaker ID e quindi **speaker-disjoint**. Uno split casuale mette lo stesso parlante in train e test e gonfia l'accuratezza di punti interi. Poiché il paper dichiara i tre numeri, abbiamo un test di correttezza gratuito e lo rendiamo bloccante.

`build_cache()` materializza ogni split in un `.npy int16` di forma $[N, 16000]$: 2,72 GB per il training, ~3,4 GB in totale. Le clip più corte di un secondo (l'**11,6 %** del dataset) vengono zero-paddate a destra.

10.2 `src/data/dataset.py`

Dataset e DataLoader sulla cache. Restituisce forme d'onda float32 in $[-1, 1]$; spettrogramma e augmentation avvengono sul batch *in GPU*.

LA MEMMAP NON ATTRAVERSA IL CONFINO DI PROCESSO

Su Windows il DataLoader crea i worker con *spawn*, che **pickla l'oggetto Dataset** per inviarlo a ogni processo. Con la memmap come attributo dell'istanza, pickle tenta di serializzare 2,7 GB dentro una pipe e fallisce con `OSError: [Errno 22] Invalid argument`.

Soluzione: apertura pigra tramite `@property` e `__getstate__` che rimuove l'handle dallo stato serializzato. Ogni worker riapre la propria vista sullo stesso file, e il sistema operativo condivide le pagine fisiche — che è il comportamento voluto. Coperto da un test di regressione che verifica che il blob pickle resti sotto i 100 KB.

Da ricordare: la cache è scritta **in ordine di classe** (34 cambi di etichetta su 84 843 campioni). Ogni iterazione senza shuffle produce quindi batch a classe singola — innocuo in valutazione, disastroso in training.

10.3 `src/data/features.py`

`LogMelSpectrogram`: waveform $[B, 16000] \rightarrow [B, 1, 64, 101]$. Vive sul device del modello. Normalizzazione per-campione opzionale (§2.6).

10.4 `src/data/augment.py`

`mixing` e `phasemix` a livello di batch, su GPU, implementate seguendo `datasets/batch_augs.py` di EAT (§6.3). Entrambe accettano un `lam` opzionale per rendere deterministici i test.

`apply_augmentations()` restituisce **sempre** target morbidi $[B, C]$, anche quando non applica nulla: così il percorso di loss è unico e la BCE non ha rami condizionali.

10.5 `src/models/frontend.py`

`EarlyConv`, parametrico su tutte le ambiguità: `channel_reading`, `stem`, `num_conv_layers`, `norm`, `pool_stride`. Espone `output_shape()`, che calcola la geometria dell'uscita *senza eseguire il forward* — usato dalla ricerca sulle configurazioni.

Contiene `ChannelLayerNorm`, che normalizza un tensore $[B, C, H, W]$ sull'asse dei canali: equivale al `layer_norm_by_dim(x, 1)` di SparseFormer. Il default `norm="layernorm"` riproduce la sequenza del riferimento; `"batchnorm"` è la nostra variante e `"none"` la lettura più letterale del paper.

10.6 `src/models/transformer.py`

MHSA, feed-forward, blocco pre-norm, codifica posizionale, stack. Scritto per esteso con `einops`.

Verifica di correttezza: copiando i nostri pesi dentro `nn.MultiheadAttention` di PyTorch, la differenza massima delle uscite è **esattamente 0,0**. Non plausibilità: equivalenza.

10.7 `src/models/dense.py`

Assembla front-end, formazione della sequenza, codifica posizionale, encoder e testa. Tutti i gradi di libertà passano dal costruttore, perché sono oggetto di ricerca e non scelte fatte.

10.8 `src/flops.py`

Due contatori indipendenti — `torch.utils.flop_counter` e `fvcore` — più gli extra manuali per `grid_sample` e la misura di latenza. Le tre avvertenze (FLOPs $\neq$ MAC, `grid_sample` invisibile, misurare in inferenza con batch 1) sono documentate nel file.

10.9 `src/utils.py`

`seed_everything`, `ModelEMA`, `load_config` con risoluzione della chiave `defaults:` (ereditarietà fra configurazioni), e `param_groups` per il weight decay selettivo (criterio `ndim == 1`, §5.2).

10.10 `src/train.py`

Il training loop. Ogni run è determinato dal solo file di configurazione più il seed; la config viene archiviata accanto ai risultati, così è riproducibile senza dover ricordare quali flag erano stati passati.

Struttura di un'epoca: si carica la forma d'onda, si applicano le augmentation *sul batch in GPU*, si calcola il log-mel, si passa al modello, BCE sui target multi-hot, passo di ottimizzazione, passo dello scheduler, aggiornamento EMA. Poi due valutazioni su validation, una sul modello EMA e una sui pesi correnti.

PERCHÉ SI VALUTANO ENTRAMBI I MODELLI

Il numero che conta è quello EMA — è ciò che i paper riportano. Ma valutare anche i pesi correnti costa poco e dice qualcosa: se il divario fra i due si allarga, l'ottimizzazione sta oscillando e l'EMA sta facendo un lavoro di stabilizzazione consistente; se coincidono, la traiettoria è già liscia. È una diagnostica gratuita sul comportamento dell'ottimizzatore.

Scrivi in `results/<tag>/: metrics.csv` per epoca, `best.pt` e `last.pt`, `summary.json`, log TensorBoard. I checkpoint si salvano in modo **atomico** (scrittura su file temporaneo e rinomina), così un'interruzione — su un portatile, per surriscaldamento o chiusura del coperchio — non lascia mai un checkpoint corrotto. `--resume` riparte da `last.pt` ripristinando anche stato dell'ottimizzatore e dello scheduler.

10.11 `scripts/evaluate.py`

Valutazione finale sul test set, con **guardia contro l'uso ripetuto**. Vedi §11.4.

10.10 tests/test_pipeline.py

19 test, nessuno dei quali richiede il dataset. Coprono: costanti del protocollo, forme del front-end, normalizzazione per-campione, invarianti delle augmentation, picklabilità del Dataset, rapporto $2\times$ fra i contatori, comportamento dell'EMA, riproducibilità dei seed.

11 · Protocollo sperimentale

11.1 Dataset e split

Split	Campioni	Uso
train	84 843	addestramento
validation	9 981	scelta degli iperparametri e del checkpoint
test	11 005	valutazione finale, una sola volta

35 classi, 16 kHz, clip zero-paddate a un secondo. Sbilanciamento fra classi nel training: da 1 256 a 3 250 campioni, cioè un fattore 2,6 — non estremo, coerente con l'uso dell'accuratezza semplice come metrica, che è quella riportata dal paper.

11.2 Prestazioni della pipeline dati

throughput ~24 600 campioni/s -> ~3,5 s per epoca di soli dati
 picco memoria GPU 59 MB (solo front-end) su 8192 disponibili

La pipeline dati **non sarà mai il collo di bottiglia**: il costo di un'epoca è interamente il modello.

11.3 Costo del training misurato

configurazione	parametri	s/epoca	100 epoche
d=128 L=8	1,79 M	15,6	26,0 min
d=224 L=8	5,19 M	23,7	39,5 min
d=128 L=24	4,96 M	43,8	73,0 min

Le ultime due righe hanno capacità quasi identica ma tempi in rapporto 1,85. A queste dimensioni la GPU è limitata dal **lancio dei kernel**, non dal calcolo: 24 layer significano tre volte le chiamate CUDA su matrici troppo piccole per saturare gli SM. È la dimostrazione misurata, sul nostro hardware, che **i FLOPs non predicono la latenza** — e la ragione per cui, a parità di parametri, preferiamo la larghezza alla profondità.

IL COSTO REALE DEL TRAINING È TRE VOLTE LA STIMA EVIDENZA

La tabella sopra misurava il *solo* encoder su dati sintetici. Il training completo, misurato: **~100 s per epoca**, non 24. Il fattore ~4 viene da quattro contributi che il benchmark non includeva:

- la sequenza reale è di **51 frame**, non 26 — il benchmark usava la geometria del pooling (2,2), prima che deducessimo (2,1);
- il calcolo del **log-mel** a ogni batch;
- le **augmentation**, che per *phasemix* includono una STFT e una iSTFT complete;
- **due** passate di validation per epoca, sul modello EMA e sui pesi correnti.

Anche il picco di memoria sale da 266 MB a **2,7 GB**, sempre ampiamente entro gli 8 GB disponibili.

Budget rivisto: ~2,8 ore per un run da 100 epoche, quindi circa **17 ore** per i sei run della Fase 3 (due varianti di codifica posizionale × tre seed) invece delle 4 stimate.

11.3-bis La precisione mista non serve EVIDENZA

Ipotesi ragionevole: attivare l'autocast **bf16** dovrebbe ridurre i tempi in modo sensibile. Implementata e misurata su un'epoca completa:

```
fp32: 101,7 s/epoca  val 31,81%  loss 0,2015
bf16: 101,7 s/epoca  val 31,91%  loss 0,2015
```

Nessun guadagno. Non è un errore di configurazione: il `resolved_config.json` del run registra `amp: bf16`, e il contesto di autocast verificato separatamente produce tensori `bfloat16`.

PERCHÉ — ED È COERENTE CON TUTTO IL RESTO

Il modello è **limitato dal lancio dei kernel**, non dall'aritmetica. Con $d = 224$, sequenza 51 e batch 64 le matrici sono troppo piccole perché i tensor core facciano differenza; il tempo se lo prendono l'overhead di lancio CUDA e le parti che non sono moltiplicazioni di matrici — il mel, la STFT e iSTFT di *phasemix*, l'aggiornamento dell'EMA, la misura della norma del gradiente.

È lo stesso fenomeno misurato altre due volte: $d=128$ con 24 layer che costa $1,85 \times d=224$ con 8 layer a parità di parametri, e i FLOPs che non predicono la latenza. **Tre misure indipendenti che convergono sulla stessa spiegazione.**

Che le due epoche coincidano a 0,1 s di distanza non è una coincidenza sospetta ma la conferma della tesi: il tempo è determinato dal *numero* di lanci, identico nei due casi, non dalla precisione con cui si calcola.

Conseguenza: `amp` resta `none`. Il codice è pronto e testato, ma attivarlo aggiungerebbe una variabile numerica in cambio di nulla. La leva per la velocità, se servisse, sarebbe un batch più grande — ma 64 è dichiarato dal paper.

11.3-ter Tracciamento degli esperimenti

Tre destinazioni dietro una sola interfaccia (`src/tracking.py`), con degrado controllato: se W&B non è installato, non c'è login o cade la rete, **il run prosegue** e scrive comunque CSV e TensorBoard. Un esperimento da tre ore non deve morire perché un servizio esterno non risponde.

- **CSV** — l'unica fonte che sopravvive a tutto, nella cartella del run;

- **TensorBoard** — locale e istantaneo, utile mentre il run gira;
- **Weights & Biases** — il confronto *fra* run, che è ciò che serve con tre seed per configurazione e più configurazioni da mettere a confronto. Con `mode: offline` funziona senza rete e si sincronizza dopo.

Si registrano per epoca: loss di training, **norma globale del gradiente**, learning rate, accuratezza di validation sul modello EMA e sui pesi correnti, secondi per epoca. La norma del gradiente costa nulla — `clip_grad_norm_` con soglia infinita la misura senza tagliare — e una norma che esplode o collassa segnala un problema molto prima che si veda sulla loss.

Il divario fra accuratezza EMA e non-EMA è a sua volta una diagnostica: se si allarga, l'ottimizzazione sta oscillando e la media mobile sta lavorando; se coincidono, la traiettoria è già liscia.

11.3-quater Analisi per classe

A fine training si ricarica il checkpoint migliore e si produce, **su validation**, un rapporto per classe con accuratezza, supporto, classi peggiori e coppie più confuse (`validation_report.json`). Lo stesso avviene sul test set in `scripts/evaluate.py`.

Si riporta anche l'**accuratezza bilanciata**, cioè la media delle accuratezze per classe. Con uno sbilanciamento di 2,6× può divergere sensibilmente da quella globale, e la coppia di numeri dice più di ciascuno dei due.

PERCHÉ LE COPPIE CONFUSE E NON UNA MAPPA DI CALORE

Una matrice 35×35 disegnata è quasi illeggibile. L'elenco delle coppie più confuse è più utile in diagnosi e all'orale: se il modello scambia *seven* con *six* o *forward* con *four* sta facendo errori fonologicamente sensati, e la cosa si commenta; se scambia coppie senza somiglianza acustica, c'è qualcosa che non va nella pipeline. Già dopo una sola epoca di prova le confusioni osservate erano del primo tipo, il che è un segnale che la catena funziona.

11.4 Disciplina sperimentale

- **≥ 3 seed** per ogni configurazione riportata, con media e deviazione standard. Motivazione empirica: nella Tabella 3 del paper l'ablation sui token non è monotona (16 → 97,53 %, 25 → 97,20 %, 36 → 97,94 %) su singolo seed, il che suggerisce un rumore di 0,3–0,4 punti, paragonabile a diverse delle differenze discusse.
- **Il test set si tocca una volta sola**, alla fine, sul modello selezionato in validation. La guardia non è un promemoria ma un meccanismo: `scripts/evaluate.py` scrive `TEST_EVALUATED.json` nella cartella del run al primo utilizzo e si rifiuta di ripartire. Con `--force` si può insistere, ma l'evento viene registrato nello storico del file, così resta traccia di quante volte è successo. Motivazione: valutare ripetutamente il test cambiando qualcosa in mezzo equivale a selezionare su di esso, e l'errore *non produce alcun sintomo visibile* — il numero sembra buono, semplicemente non è più una stima onesta della generalizzazione.
- Si valuta il **modello EMA**.
- Con mixing e phasemix sempre attive, **l'accuratezza di training non è interpretabile**: il segnale utile è solo la validation.
- Ogni run è riproducibile dal solo file di configurazione, che viene archiviato accanto ai risultati.

11.5 Target di riproduzione

Modello	Params	FLOPs	Accuratezza	Nota
Sparse-transformer (N=4, P=36)	2,87 M	0,055 G	96,88 %	obiettivo Fase 4

Modello	Params	FLOPs	Accuratezza	Nota
Dense-transformer	4,80 M	0,645 G	96,67 %	obiettivo Fase 3
EAT-S	5,30 M	0,373 G	98,15 %	<i>citato</i> , non rimisurato
HTS-AT	28,80 M	4,066 G	98,00 %	citato
SimPF (MobileNetV2)	3,40 M	0,244 G	95,60 %	citato

12 · Riferimenti

PAPER DEL PROGETTO

- Kavaki, H. S., & Mandel, M. I. (2025). *Audio Sparse-Transformer for Speech Classification*. ICASSP 2025, 1–5.
- Gazneli, A., Zimerman, G., Ridnik, T., Sharir, G., & Noy, A. (2022). *End-to-End Audio Strikes Back*. arXiv:2204.11479. Codice: `github.com/Alibaba-MIIL/AudioClassification` — file `datasets/batch_augs.py` per le augmentation di label-mixing.

ANCESTORS DEL METODO

- Gao, Z., Tong, Z., Wang, L., & Shou, M. Z. (2023). *SparseFormer: Sparse Visual Recognition via Limited Latent Tokens*. arXiv:2304.03768. Codice: `github.com/showlab/sparseformer` — file `imagenet/models/sparseformer.py` per la v1.
- Gao, Z., Wang, L., Han, B., & Guo, S. (2022). *AdaMixer*. CVPR 2022.
- Ren, S., He, K., Girshick, R., & Sun, J. (2015). *Faster R-CNN*. NeurIPS 28.
- Xiao, T., et al. (2021). *Early Convolutions Help Transformers See Better*. NeurIPS 34.

FONDAMENTI

- Vaswani, A., et al. (2017). *Attention Is All You Need*. NeurIPS 30.
- Dosovitskiy, A., et al. (2020). *An Image Is Worth 16×16 Words*. ICLR 2021.
- Kingma, D., & Ba, J. (2014). *Adam*. arXiv:1412.6980.
- Loshchilov, I., & Hutter, F. (2018). *Decoupled Weight Decay Regularization*. ICLR 2019.
- Smith, L. N. (2018). *A Disciplined Approach to Neural Network Hyper-Parameters*. arXiv:1803.09820.
- Tarvainen, A., & Valpola (2017). *Mean Teachers Are Better Role Models*. NeurIPS 30.
- Hendrycks, D., & Gimpel, K. (2016). *Gaussian Error Linear Units*. arXiv:1606.08415.
- Dumoulin, V., & Visin, F. (2016). *A Guide to Convolution Arithmetic for Deep Learning*. arXiv:1603.07285.
- Rogozhnikov, A. (2022). *Einops*. ICLR 2022.
- Warden, P. (2018). *Speech Commands*. arXiv:1804.03209.
- Tokozume, Y., Ushiku, Y., & Harada, T. (2017). *Learning from Between-Class Examples*. arXiv:1711.10282.

MODELLI DI CONFRONTO

- Berg, A., O'Connor, M., & Tairum Cruz, M. (2021). *Keyword Transformer*. arXiv:2104.00769.
- Gong, Y., Chung, Y.-A., & Glass, J. (2021). *AST: Audio Spectrogram Transformer*. arXiv:2104.01778.
- Chen, K., et al. (2022). *HTS-AT*. ICASSP 2022.

Manuale tecnico del progetto d'esame Bo31278 — Deep Learning, Fall 2025, Università di Firenze. Documento vivo: sorgente in `docs/manuale_tecnico.html`, rigenerabile con `scripts\build_docs.ps1`. Le formule di §7 sono trascritte dal paper originale; le derivazioni sono nostre. I marcatori distinguono ciò che il paper dichiara, ciò che assumiamo e ciò per cui abbiamo evidenza sperimentale.